

# Máxima Verossimilhança - Parte II

Bibliografia: Greene

Claudio Lucinda

FEA/USP



# Overview

- 1 ML Condicional
- 2 Os Três Testes Canônicos - no contexto de ML



# ML Condicional

- Até o momento, fomos bastante soltos com o vetor  $\mathbf{y}$ , sem falar sobre o fato que na maior parte das vezes nós temos regressores neste modelo, e seria melhor que particionássemos este vetor em variáveis independentes e dependentes do modelo.
- Vamos representar  $\mathbf{x}_i$  como sendo um conjunto de variáveis aleatórias e constantes que entram na distribuição condicional de  $y_i$ .
- Particionando a distribuição conjunta de  $y_i$  e  $\mathbf{x}_i$  no produto da distribuição condicional e a marginal, podemos escrever a log-verossimilhança como sendo

$$\ln L(\alpha \mid \text{data}) = \sum_{i=1}^n \ln f(y_i, \mathbf{x}_i \mid \alpha) = \sum_{i=1}^n \ln f(y_i \mid \mathbf{x}_i, \alpha) + \sum_{i=1}^n \ln g(\mathbf{x}_i \mid \alpha),$$



# ML Condicional

- Vamos assumir que o processo gerador de  $\mathbf{x}_i$  acontece externamente ao modelo de interesse.
  - Nem sempre isso é verdade - se tivéssemos endogeneidade, esse modelo teria que ser estudado também.
- Isso implica que os parâmetros do modelo  $g(\mathbf{x}_i | \alpha)$  não são os mesmos que aparecem em  $f(y_i | \mathbf{x}_i, \alpha)$ .
- Portanto, podemos particionar  $\alpha$  em  $[\theta, \delta]$  e a Log-Verossimilhança fica sendo

$$\ln L(\theta, \delta | \mathbf{data}) = \sum_{i=1}^n \ln f(y_i, \mathbf{x}_i | \alpha) = \sum_{i=1}^n \ln f(y_i | \mathbf{x}_i, \theta) + \sum_{i=1}^n \ln g(\mathbf{x}_i | \delta).$$



# ML Condicional

Desde que  $\theta$  e  $\delta$  não possuam elementos em comum nem restrições que os conectem, (tais como  $\theta + \delta = 1$ ), podemos analisar as duas partes da Log-Verossimilhança separadamente e, a distribuição marginal de  $\mathbf{x}_i$  não vai ser de muito interesse.

Os resultados assintóticos aqui precisam levar em conta a presença de  $\mathbf{x}_i$  nas funções e derivadas de  $\ln f(y_i | \mathbf{x}_i, \theta)$ .

Vamos supor dados razoavelmente comportados, tal que médias amostrais tais como

$$(1/n) \ln L(\theta | \mathbf{y}, \mathbf{X}) = \frac{1}{n} \sum_{i=1}^n \ln f(y_i | \mathbf{x}_i, \theta)$$

E o gradiente da função com respeito a  $\theta$  irão convergir em probabilidade para suas esperanças populacionais.



# Condições

- Espaço de parâmetros. Espaço de parâmetros podem ter “vãos” e não convexidades que bagunçam os procedimentos. A função verossimilhança precisa ser uma função contínua de um espaço convexo de parâmetros (ainda que possa ser não limitado, como em  $\sigma > 0$  no modelo de regressão).
- Identificação (numérica). Ou seja, a estimação precisa ser factível.
- Dados bem comportados. As leis dos grandes números tem que se aplicar às médias amostrais dos dados e alguma forma de Teorema Central do Limite precisa ser aplicável ao gradiente.




# Os Três Testes Canônicos - no contexto de ML

- Teste de razão de verossimilhança. Se a restrição  $c(\theta) = 0$  for válida, sua imposição não deve levar a uma grande redução na função de log-verossimilhança. Portanto, baseamos o teste na diferença,  $\ln L_U - \ln L_R$ , onde  $L_U$  é o valor da função de verossimilhança no valor irrestrito de  $\theta$  e  $L_R$  é o valor da função de verossimilhança na estimativa restrita.
- Teste Wald. Se a restrição for válida, então  $c(\hat{\theta}_{\text{MLE}})$  deve ser próximo de zero, pois o MLE é consistente. Portanto, o teste é baseado em  $c(\hat{\theta}_{\text{MLE}})$ . Rejeitamos a hipótese se esse valor for significativamente diferente de zero.
- Teste do multiplicador de Lagrange. Se a restrição for válida, o estimador restrito deve estar próximo do ponto que maximiza a verossimilhança logarítmica. Portanto, a inclinação da função de verossimilhança logarítmica deve ser próxima de zero no estimador restrito. O teste é baseado na inclinação da verossimilhança logarítmica no ponto em que a função é maximizada sujeita à restrição.



# Os Três Testes Canônicos - no contexto de ML





# Teste de Razão de Verossimilhança

O teste de Razão de Verossimilhança é

$$\lambda = \frac{\hat{L}_R}{\hat{L}_U}.$$

Por construção, esta função é limitada entre zero e um. As duas verossimilhanças são positivas, e  $\hat{L}_R$  não pode ser maior que  $\hat{L}_U$ . Se  $\lambda$  é pequeno demais, temos motivos pra rejeitar as restrições.

Sob regularidade e sob  $H_0$ , a distribuição em grandes amostras  $-2 \ln \lambda$  é qui-quadrada, com graus de liberdade iguais ao número de restrições impostas.

A hipótese nula é rejeitada se esse valor exceder o valor crítico apropriado das tabelas qui-quadrado.



# Teste de Wald

- Uma deficiência prática do teste de razão de verossimilhança é que ele geralmente requer a estimativa de vetores de parâmetros restritos e irrestritos.
- Em modelos complexos, uma ou outra dessas estimativas pode ser muito difícil de calcular. Ou quando tanto a hipótese nula ou a alternativa são modelos restritos?
- Um dos testes para lidar com isso é o de Wald, baseado em um estimador que é assintoticamente distribuído normalmente.

Se  $\mathbf{x} \sim N_J[\boldsymbol{\mu}, \boldsymbol{\Sigma}]$ , então  $(\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \sim \text{qui} - \text{quadrado } [J]$

- No cenário de um teste de hipótese, sob a hipótese de que  $E(\mathbf{x}) = \boldsymbol{\mu}$ , a forma quadrática tem distribuição qui-quadrada.
- No entanto, se a hipótese de que  $E(\mathbf{x}) = \boldsymbol{\mu}$  for falsa, então a forma quadrática que acabamos de fornecer será, em média, maior do que seria se a hipótese fosse verdadeira.



# Teste de Wald para hipóteses

Seja  $\hat{\theta}$  o vetor de estimativas de parâmetros obtidas sem restrições. Nós hipotetizamos um conjunto de restrições

$$H_0 : \mathbf{c}(\theta) = \mathbf{q}$$

A estatística de teste é

$$W = [\mathbf{c}(\hat{\theta}) - \mathbf{q}]' (\text{Asy. Var}[\mathbf{c}(\hat{\theta}) - \mathbf{q}])^{-1} [\mathbf{c}(\hat{\theta}) - \mathbf{q}]$$

Sob  $H_0$ , em grandes amostras,  $W$  tem uma distribuição qui-quadrada com graus de liberdade igual ao número de restrições [ou seja, o número de equações em  $\mathbf{c}(\hat{\theta}) - \mathbf{q} = \mathbf{0}$ ].



# Estimando a Variância das Restrições

$$\begin{aligned} \text{Est. Asy.} \quad \text{Var}[\mathbf{c}(\hat{\boldsymbol{\theta}}) - \mathbf{q}] &= \hat{\mathbf{C}} \text{ Est. Asy. Var}[\hat{\boldsymbol{\theta}}] \hat{\mathbf{C}}', \\ \hat{\mathbf{C}} &= \left[ \frac{\partial \mathbf{c}(\hat{\boldsymbol{\theta}})}{\partial \hat{\boldsymbol{\theta}}'} \right]. \end{aligned}$$

Para restrições lineares nos parâmetros:

$$\begin{aligned} H_0 : \mathbf{c}(\boldsymbol{\theta}) - \mathbf{q} &= \mathbf{R}\boldsymbol{\theta} - \mathbf{q} = \mathbf{0}, \\ \hat{\mathbf{C}} &= \left[ \frac{\partial \mathbf{c}(\hat{\boldsymbol{\theta}})}{\partial \hat{\boldsymbol{\theta}}'} \right] = \mathbf{R}', \\ \text{Est. Asy. Var}[\mathbf{c}(\hat{\boldsymbol{\theta}}) - \mathbf{q}] &= \mathbf{R} \text{ Est. Asy. Var}[\hat{\boldsymbol{\theta}}] \mathbf{R}, \\ W &= [\mathbf{R}\hat{\boldsymbol{\theta}} - \mathbf{q}]' \left[ \mathbf{R} \text{ Est. Asy. Var}(\hat{\boldsymbol{\theta}}) \mathbf{R}' \right]^{-1} [\mathbf{R}\hat{\boldsymbol{\theta}} - \mathbf{q}] \end{aligned}$$



# Teste do Multiplicador de Lagrange

O terceiro procedimento de teste é o multiplicador de Lagrange (LM) ou teste de score eficiente (ou apenas score), a partir do modelo restrito ao invés do modelo irrestrito. Suponha que maximizamos a log-verossimilhança sujeita ao conjunto de restrições  $\mathbf{c}(\boldsymbol{\theta}) - \mathbf{q} = \mathbf{0}$ . Seja  $\boldsymbol{\lambda}$  um vetor de multiplicadores de Lagrange e defina a função Lagrangeana:

$$\ln L^*(\boldsymbol{\theta}) = \ln L(\boldsymbol{\theta}) + \boldsymbol{\lambda}'(\mathbf{c}(\boldsymbol{\theta}) - \mathbf{q})$$

A solução do problema passa pelas CPO's:

$$\begin{aligned}\frac{\partial \ln L^*}{\partial \boldsymbol{\theta}} &= \frac{\partial \ln L(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} + \mathbf{C}'\boldsymbol{\lambda} = \mathbf{0}, \\ \frac{\partial \ln L^*}{\partial \boldsymbol{\lambda}} &= \mathbf{c}(\boldsymbol{\theta}) - \mathbf{q} = \mathbf{0},\end{aligned}$$



## Teste do Multiplicador de Lagrange II:

No máximo restrito, as derivadas da função de log-verossimilhança são

$$\frac{\partial \ln L(\hat{\theta}_R)}{\partial \hat{\theta}_R} = -\hat{\mathbf{C}}' \hat{\boldsymbol{\lambda}} = \hat{\mathbf{g}}_R.$$

A estatística de teste do multiplicador de Lagrange é

$$\mathbf{LM} = \left( \frac{\partial \ln L(\hat{\theta}_R)}{\partial \hat{\theta}_R} \right)' [\mathbf{I}(\hat{\theta}_R)]^{-1} \left( \frac{\partial \ln L(\hat{\theta}_R)}{\partial \hat{\theta}_R} \right).$$

Sob a hipótese nula,  $LM$  tem uma distribuição qui-quadrada limite com graus de liberdade iguais ao número de restrições.



## Teste LM III:

Seja  $\hat{\mathbf{g}}_{iR}$  denotando o  $i$  o termo no gradiente da função de log-verossimilhança. Então,

$$\hat{\mathbf{g}}_R = \sum_{i=1}^n \hat{\mathbf{g}}_{iR} = \hat{\mathbf{G}}'_R \mathbf{i},$$

Em que  $\hat{\mathbf{G}}_R$  é a matriz  $n \times K$  com  $i$  a décima linha igual a  $\mathbf{g}'_{iR}$  e  $\mathbf{i}$  é uma coluna de 1 s. Se usarmos o estimador BHHH (produto externo de gradientes) em (17-18) para estimar o Hessiano, então

$$[\hat{\mathbf{I}}(\hat{\theta})]^{-1} = [\hat{\mathbf{G}}'_R \hat{\mathbf{G}}_R]^{-1}$$

e

$$\text{LM} = \mathbf{i}' \hat{\mathbf{G}}_R [\hat{\mathbf{G}}'_R \hat{\mathbf{G}}_R]^{-1} \hat{\mathbf{G}}'_R \mathbf{i}$$

