

GMM - Parte I

Bibliografia: Hayashi, cap. 3

Claudio Lucinda

FEA/USP



Overview

- 1 GMM
- 2 Condições de Posto e de Ordem
- 3 Normalidade Assintótica
- 4 GMM - Definição
- 5 Propriedades Assintóticas do GMM
- 6 Testes de Hipóteses



Método Generalizado dos Momentos

- A base do GMM é a seguinte. Com amostragem aleatória, e sob hipóteses razoáveis, uma estatística amostral irá convergir em probabilidade para alguma constante.
- Por exemplo, com amostragem aleatória i.i.d., $\bar{m}_2 = (1/n) \sum_{i=1}^n y_i^2$ irá convergir em mean square à variância mais o quadrado da média da variável aleatória y_i .
- Esta constante será uma função dos parâmetros – desconhecidos – da distribuição.
- Se tivermos K estatísticas amostrais, $\bar{m}_1, \dots, \bar{m}_K$, podemos estimar K parâmetros dos quais as estatísticas amostrais dependem.



GMM II

- Estes momentos serão consistentes (ou seja, convergem para as constantes relevantes), por conta de alguma versão da Lei dos Grandes Números
- Eles serão normalmente distribuídos pelo Teorema Central do Limite de Lindberg-Lévy.
- Podemos extrair as estimativas dos parâmetros vão ser consistentes pelo teorema de Slutsky, e as estimativas deles serão normalmente distribuídas pelo Método Delta.



Método Generalizado dos Momentos (Continuação)

- Etapas do GMM:
 - 1 Especificar o modelo econômico e definir os parâmetros a serem estimados.
 - 2 Identificar os momentos empíricos relevantes relacionados aos parâmetros.
 - 3 Escolher um estimador de momentos adequado.
 - 4 Resolver as equações de momento para estimar os parâmetros.
 - 5 Verificar a validade das estimativas e realizar testes de qualidade do ajuste.



GMM- Revisitando IV

O modelo de Variáveis Instrumentais é um tipo de estimador de GMM. Em muitos casos, temos que a premissa de

$$E\left(\mathbf{Z}^T \mathbf{u}\right) = 0$$

Vamos supor que, dada uma amostra grande o suficiente, mesmo assim, a covariância entre os regressores e o termo erro do modelo não converge para zero plim $N \rightarrow \infty \mathbf{Z}^T \mathbf{u} = \gamma$. Isso faz com que o estimador de XQO seja viesado e inconsistente.



Revisitando IV

No entanto, vamos supor que exista um ou um conjunto de variáveis, denotadas por \mathbf{X} que, ao mesmo tempo:

$$E(\mathbf{X}^T \mathbf{Z}) \neq 0$$

$$E(\mathbf{X}^T \mathbf{u}) = 0$$

Esta variável \mathbf{X} é chamada de instrumento para \mathbf{Z} (**essa notação é do Hayashi**). Podemos derivar o estimador de variáveis instrumentais de uma forma bem simples, desde que o número de variáveis seja igual ao número de Instrumentos:

$$E(\mathbf{X}^T \mathbf{u}) = 0$$

$$E(\mathbf{X}^T (\mathbf{Y} - \mathbf{Z}\beta)) = 0$$



IV Revisitado

Supondo os regressores fixos em amostras repetidas, temos que:

$$\mathbf{X}^T(\mathbf{Y} - \mathbf{Z}\beta) = 0$$

$$\mathbf{X}^T\mathbf{Y} - \mathbf{X}^T\mathbf{Z}\beta = 0$$

$$\hat{\beta}_{iv} = (\mathbf{X}^T\mathbf{Z})^{-1} \mathbf{X}^T\mathbf{Y}$$

Para provarmos a ausência de viés:

$$\hat{\beta}_{iv} = (\mathbf{X}^T\mathbf{Z})^{-1} \mathbf{X}^T(\mathbf{Z}\beta + \mathbf{u})$$

$$= \beta + (\mathbf{X}^T\mathbf{Z})^{-1} \mathbf{X}^T\mathbf{u}$$



IV Revisitado

Ou seja, dada a hipótese de $E(\mathbf{X}^T \mathbf{u}) = 0$, temos que o estimador é não viesado. Do ponto de vista dos erros-padrão:

$$\begin{aligned}\text{Var}(\hat{\beta}_{iv}) &= E \left[(\hat{\beta}_{iv} - \beta) (\hat{\beta}_{iv} - \beta)^T \right] = \\ &= E \left[(\mathbf{X}^T \mathbf{Z})^{-1} \mathbf{X}^T \mathbf{u} \mathbf{u}^T \mathbf{X} (\mathbf{X}^T \mathbf{Z})^{-1} \right]\end{aligned}$$

Ou, alternativamente,

$$\text{Var}(\hat{\beta}_{iv}) = \sigma^2 (\mathbf{X}^T \mathbf{Z})^{-1} \mathbf{X}^T \mathbf{X} (\mathbf{X}^T \mathbf{Z})^{-1}$$



IV Revisitado

O problema é que temos que ter a dimensão de \mathbf{X} igual à dimensão de \mathbf{Z} . E se tivermos mais instrumentos do que variáveis endógenas? a idéia é que o sistema subjacente é sobre-identificado. O que fazer neste caso? Uma sugestão seria apenas usar os instrumentos na quantidade certinha, mas aí estaríamos desperdiçando informações. Outra forma interessante seria usar, no lugar dos \mathbf{X} diretamente, a projeção dos \mathbf{X} no espaço determinado pelos \mathbf{Z} :

$$\hat{\mathbf{Z}} = \mathbf{X} (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Z} = \mathbf{P}_X \mathbf{Z}$$

Neste caso, as fórmulas ficam:

$$\hat{\beta}_{iv} = \left(\mathbf{Z}^T \mathbf{P}_X \mathbf{Z} \right)^{-1} \mathbf{Z}^T \mathbf{P}_X \mathbf{Y}$$

A Variância, por outro lado, fica sendo:

$$\text{Var} \left(\hat{\beta}_{iv} \right) = \sigma^2 \left(\mathbf{Z}^T \mathbf{P}_X \mathbf{Z} \right)^{-1}$$



Condição de Posto

Suposição 3.4 (condição de posto para identificação): A $K \times L$ matriz $E(\mathbf{x}_i \mathbf{z}_i')$ é de posto completo na dimensão coluna (ou seja, seu posto é igual a L , o número de suas colunas). Denotamos esta matriz por Σ_{xz} .

Intuição, para um modelo linear nos parâmetros. Podemos escrevê-lo como $\mathbf{x}_i \cdot y_i = \mathbf{x}_i \mathbf{z}_i' \tilde{\delta}$. Ou um sistema de K equações lineares:

$$E(\mathbf{x}_i \cdot y_i) - E(\mathbf{x}_i \mathbf{z}_i') \tilde{\delta} = \mathbf{0} \quad \text{or} \quad \begin{matrix} \Sigma_{xz} & \tilde{\delta} \\ (K \times L) & (L \times 1) \end{matrix} \begin{matrix} (K \times 1) \\ (K \times 1) \end{matrix} = \begin{matrix} \sigma_{xy}, \\ (K \times 1) \end{matrix}$$

Em que

$$\sigma_{xy} \equiv E(\mathbf{x}_i \cdot y_i), \quad \Sigma_{xz} \equiv E(\mathbf{x}_i \mathbf{z}_i')$$



Condição de Ordem

Como $\text{rank}(\Sigma_{xz}) < L$ se $K < L$, uma condição necessária para identificação é que

$$K \text{ (= nro. variáveis predeterminadas)} \geq L \text{ (= nro. regressores)}.$$

Isso é chamado de condição de ordem para identificação. Pode ser afirmado de diferentes maneiras. Visto que K é também o número de condições de ortogonalidade e L é o número de parâmetros, a condição de ordem pode ser exposta de forma equivalente como

$$\text{nro. condições de ortogonalidade} \geq \text{nro. parâmetros}.$$

Ao subtrair o número de regressores predeterminados de ambos os lados da desigualdade, obtemos outra declaração equivalente:

$$\# \text{variáveis predeterminadas excluídas da equação} \geq \# \text{regressores endógenos}.$$



Condições de Ordem II

Dependendo se a condição de ordem é satisfeita, dizemos que a equação é

- Sobreidentificada se a condição de posto for satisfeita e $K > L$,
- Exatamente identificada ou apenas identificada se a condição de posto for satisfeita e $K = L$
- Subidentificada (ou não identificada) se a condição do posto não for satisfeita (ou seja, se $K < L$).

Como a condição de ordem é uma condição necessária para identificação, uma falha na condição de ordem significa que a equação não é identificada.



Condição Necessária para Normalidade Assintótica

g_i é uma sequência de diferenças em martingale (MDS) com segundos momentos finitos:

Seja $\mathbf{g}_i \equiv \mathbf{x}_i \cdot \varepsilon_i$. Temos que \mathbf{g}_i é uma MDS (e $E(\mathbf{g}_i) = \mathbf{0}$).

A matriz $K \times K$ de momentos cruzados, $E(\mathbf{g}_i \mathbf{g}_i')$, é não singular. Definindo $S = Avar(\bar{\mathbf{g}})$ (a variância da distribuição limite de $\sqrt{n}\bar{\mathbf{g}}$, where $\bar{\mathbf{g}} \equiv \frac{1}{n} \sum_{i=1}^n \mathbf{g}_i$). Pela Hipótese 3.2 do Hayashi e o TCL de MDS ergódico estacionário, $\mathbf{S} = E(\mathbf{g}_i \mathbf{g}_i')$.



Intuitivamente...

Uma forma mais intuitiva de entender essa coisa do MDS é:

$$E(\varepsilon_i \mid \varepsilon_{i-1}, \dots, \varepsilon_1, \mathbf{x}_i, \mathbf{x}_{i-1}, \dots, \mathbf{x}_1) = 0$$

Que em palavras quer dizer que, além de ser um MDS, o termo erro tem que ser ortogonal não apenas ao instrumentos contemporâneos mas aos defasados também. Depois vamos ver isso com mais cuidado.



GMM - Definição

Seja $\widehat{\mathbf{W}}$ uma matriz definida positiva simétrica $K \times K$, possivelmente dependente da amostra, tal que $\widehat{\mathbf{W}} \rightarrow_{\text{mathrmp}} \mathbf{W}$ com o tamanho da amostra n tendendo a infinito, e \mathbf{W} simétrico e positivo definido. O estimador GMM de δ , denotado $\hat{\delta}(\widehat{\mathbf{W}})$, é

$$\hat{\delta}(\widehat{\mathbf{W}}) \equiv \underset{\tilde{\delta}}{\operatorname{argmin}} J(\tilde{\delta}, \widehat{\mathbf{W}}),$$

where

$$J(\tilde{\delta}, \widehat{\mathbf{W}}) \equiv n \cdot \mathbf{g}_n(\tilde{\delta})' \widehat{\mathbf{W}} \mathbf{g}_n(\tilde{\delta})$$



GMM – Definição II

Quando $\mathbf{g}_n(\tilde{\boldsymbol{\delta}})$ é linear nos coeficientes $\tilde{\boldsymbol{\delta}}$ a função objetivo é quadrática no $\tilde{\boldsymbol{\delta}}$ quando a equação é linear:

$$J(\tilde{\boldsymbol{\delta}}, \widehat{\mathbf{W}}) = n \cdot \left(\mathbf{s}_{xy} - \mathbf{s}_{xz} \tilde{\boldsymbol{\delta}} \right)' \widehat{\mathbf{W}} \left(\mathbf{s}_{xy} - \mathbf{s}_{xz} \tilde{\boldsymbol{\delta}} \right)$$

Podemos resolver e chegar a uma solução analítica nesse caso:

$$\text{Estimador GMM: } \hat{\boldsymbol{\delta}}(\widehat{\mathbf{W}}) = \left(\mathbf{s}_{xz}' \widehat{\mathbf{W}} \mathbf{s}_{xz} \right)^{-1} \mathbf{s}_{xz}' \widehat{\mathbf{W}} \mathbf{s}_{xy}$$



Propriedades Assintóticas do GMM

Resultados assintóticos para $\hat{\delta}(\widehat{\mathbf{W}})$ válidos para qualquer escolha de $\widehat{\mathbf{W}}$ são

(a) (Consistência) $\text{plim}_{n \rightarrow \infty} \hat{\delta}(\widehat{\mathbf{W}}) = \delta$.

(b) (Normalidade Assintótica) Dada a condição de alguns slides pra trás

$$\sqrt{n}(\hat{\delta}(\widehat{\mathbf{W}}) - \delta) \xrightarrow{d} N(\mathbf{0}, \text{Avar}(\hat{\delta}(\widehat{\mathbf{W}}))) \quad \text{as } n \rightarrow \infty$$

em que

$$\text{Avar}(\hat{\delta}(\widehat{\mathbf{W}})) = (\boldsymbol{\Sigma}'_{xz} \mathbf{W} \boldsymbol{\Sigma}_{xz})^{-1} \boldsymbol{\Sigma}'_{xz} \mathbf{W} \mathbf{S} \mathbf{W} \boldsymbol{\Sigma}_{xz} (\boldsymbol{\Sigma}'_{xz} \mathbf{W} \boldsymbol{\Sigma}_{xz})^{-1}$$

Lembrando: $(\boldsymbol{\Sigma}_{xz} \equiv E(\mathbf{x}_i \mathbf{z}'_i), \mathbf{S} = E(\mathbf{g}_i \mathbf{g}'_i) = E(\varepsilon_i^2 \mathbf{x}_i \mathbf{x}'_i), \mathbf{W} \equiv \text{plim } \widehat{\mathbf{W}}.)$



Propriedades Assintóticas II

(c) (Estimador Consistente de Avar ($\hat{\delta}(\widehat{\mathbf{W}})$)) Suponha um estimador consistente de, $\widehat{\mathbf{S}}$, de $\mathbf{S}(K \times K)$. Podemos mostrar que $\text{Avar}(\hat{\delta}(\widehat{\mathbf{W}}))$ é estimado de forma consistente por

$$\text{Avar}(\hat{\delta}(\widehat{\mathbf{W}})) \equiv \left(\mathbf{S}'_{xz} \widehat{\mathbf{W}} \mathbf{S}_{xz} \right)^{-1} \mathbf{S}'_{xz} \widehat{\mathbf{W}} \widehat{\mathbf{S}} \widehat{\mathbf{W}} \mathbf{S}_{xz} \left(\mathbf{S}'_{xz} \widehat{\mathbf{W}} \mathbf{S}_{xz} \right)^{-1}$$

Em que \mathbf{S}_{xz} é a média amostral de $\mathbf{x}_i \mathbf{z}'_i$:

$$\underset{(K \times L)}{\mathbf{S}_{xz}} \equiv \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{z}'_i$$



Teste t

Supondo a existência de um estimador consistente $\widehat{\mathbf{S}}$ de $\mathbf{S}(\equiv \text{Avar}(\bar{\mathbf{g}}) = \text{E}(\mathbf{g}_i \mathbf{g}_i'))$. Seja

$$\text{Avar}(\widehat{\delta}(\widehat{\mathbf{W}})) \equiv \left(\mathbf{S}'_{xz} \widehat{\mathbf{W}} \mathbf{S}_{xz} \right)^{-1} \mathbf{S}'_{xz} \widehat{\mathbf{W}} \widehat{\mathbf{S}} \widehat{\mathbf{W}} \mathbf{S}_{xz} \left(\mathbf{S}'_{xz} \widehat{\mathbf{W}} \mathbf{S}_{xz} \right)^{-1}$$

Então:

(a) Sob $H_0 : \delta_\ell = \bar{\delta}_\ell$,

$$t_\ell \equiv \frac{\sqrt{n} \left(\widehat{\delta}_\ell(\widehat{\mathbf{W}}) - \bar{\delta}_\ell \right)}{\sqrt{(\text{Avar}(\widehat{\delta}(\widehat{\mathbf{W}})))_{\ell\ell}}} = \frac{\widehat{\delta}_\ell(\widehat{\mathbf{W}}) - \bar{\delta}_\ell}{SE_\ell^*} \xrightarrow{d} N(0, 1),$$

$$SE_\ell^* (\text{robust standard error}) \equiv \sqrt{\frac{1}{n} \cdot (\text{Avar}(\widehat{\delta}(\widehat{\mathbf{W}})))_{\ell\ell}}$$



Teste Wald

(b) (H0 linear) $H_0 : \mathbf{R}\delta = \mathbf{r}$ em que r é a dimensão de \mathbf{r} e $\mathbf{R}(\#r \times L)$ é posto cheio,

$$W \equiv n \cdot (\mathbf{R}\hat{\delta}(\widehat{\mathbf{W}}) - \mathbf{r})' \left\{ \mathbf{R}[\widehat{\text{Avar}}(\hat{\delta}(\widehat{\mathbf{W}}))]\mathbf{R}' \right\}^{-1} (\mathbf{R}\hat{\delta}(\widehat{\mathbf{W}}) - \mathbf{r}) \xrightarrow{d} \chi^2(\#r)$$

(c) (H0 não linear) $H_0 : \mathbf{a}(\delta) = \mathbf{0}$ tal que $\mathbf{A}(\delta)$, a $\#a \times L$ matriz de primeiras derivadas de $\mathbf{a}(\delta)$ (em que $\#a$ é a dimensão de \mathbf{a}), é contínua de posto linha cheio,

$$W \equiv n \cdot \mathbf{a}(\hat{\delta}(\widehat{\mathbf{W}}))' \left\{ \mathbf{A}(\hat{\delta}(\widehat{\mathbf{W}}))[\widehat{\text{Avar}}(\hat{\delta}(\widehat{\mathbf{W}}))]\mathbf{A}(\hat{\delta}(\widehat{\mathbf{W}}))' \right\}^{-1} \mathbf{a}(\hat{\delta}(\widehat{\mathbf{W}})) \xrightarrow{d} \chi^2(\#a)$$



LR Test - Versão GMM

A função objetivo é $J(\tilde{\delta}, \hat{\mathbf{S}}^{-1})$ para uma estimativa consistente $\hat{\mathbf{S}}$ de \mathbf{S} . O estimador restrito é definido $\bar{\delta}(\hat{\mathbf{S}}^{-1}) \equiv \underset{\tilde{\delta}}{\operatorname{argmin}} J(\tilde{\delta}, \hat{\mathbf{S}}^{-1})$ sujeito a H_0 .

O princípio da LR sugere que

$$LR \equiv J(\bar{\delta}(\hat{\mathbf{S}}^{-1}), \hat{\mathbf{S}}^{-1}) - J(\hat{\delta}(\hat{\mathbf{S}}^{-1}), \hat{\mathbf{S}}^{-1})$$

Deve ser distribuído qui-quadrado com g.l. igual ao número de restrições. E é.

