GMM – Parte I

Framework Geral e Propriedades Assintóticas

Claudio Lucinda

FEA/USP

Overview

1. Método dos Momentos – Intuição
2. Definição Formal e Notação
3. Consistência
4. Normalidade Assintótica
5. GMM Eficiente
6. Estimação de **S**
7. Inferência
8. Testes de Especificação
9. Considerações de Amostra Pequena

O Princípio do Método dos Momentos

- A ideia central do **Método dos Momentos** (MM) é simples: uma estatística amostral converge, sob hipóteses fracas, a alguma constante que é função dos parâmetros desconhecidos do modelo.
- Exemplo: com amostragem i.i.d., $\bar{y}^2 = \frac{1}{n}\sum_{i=1}^{n} y_i^2 \xrightarrow{p} \mathrm{E}(y_i^2) = \sigma^2 + \mu^2$.
- Se tivermos K condições de momento populacionais

$$\mathrm{E}[\, g(w_i, \delta_0)\,] = \mathbf{0}_{K\times 1},$$

  podemos estimá-las pelos análogos amostrais e resolver para δ.
- A consistência vem da **Lei dos Grandes Números** (LGN). A normalidade assintótica vem do **Teorema Central do Limite** (TCL) e do **Método Delta**.

O Conceito de Condição de Momento

Uma **condição de momento** é uma restrição sobre a distribuição dos dados que o verdadeiro valor do parâmetro δ_0 deve satisfazer:

$$\mathrm{E}[\, g(w_i, \delta_0)\,] = \mathbf{0}_{K\times 1}.$$

- w_i: vetor de variáveis observadas (dados do problema).
- $g(\cdot)$: função conhecida que mapeia dados e parâmetros num vetor de K condições.
- O **análogo amostral** da condição de momento é

$$\mathbf{g}_n(\tilde{\delta}) \;\equiv\; \frac{1}{n}\sum_{i=1}^{n} g(w_i, \tilde{\delta}).$$

- Pela LGN, $\mathbf{g}_n(\delta_0) \xrightarrow{p} \mathbf{0}$. O estimador de MM resolve $\mathbf{g}_n(\hat{\delta}) = \mathbf{0}$ (possível apenas quando há $K = L$ condições).

De MM para GMM

- O MM *exato* exige $K = L$ (tantas condições quanto parâmetros). Com $K > L$ o sistema é **sobre-identificado**: não é possível zerar todos os K momentos amostrais simultaneamente.
- O **Método Generalizado dos Momentos** (GMM, Hansen 1982) resolve isso minimizando uma *forma quadrática* nos momentos amostrais:

$$\hat{\delta}(\widehat{\mathbf{W}}) = \arg\min_{\tilde{\delta}} \; n \cdot \mathbf{g}_n(\tilde{\delta})' \, \widehat{\mathbf{W}} \, \mathbf{g}_n(\tilde{\delta}),$$

  onde $\widehat{\mathbf{W}}$ é uma matriz de pesos $(K \times K)$ simétrica e positiva definida.
- Nota crucial: a *escolha* de $\widehat{\mathbf{W}}$ afeta a eficiência (mas **não** a consistência) do estimador.

Notação: Objetos Populacionais vs. Amostrais

Convenção adotada neste curso

Símbolo	Definição	Dimensão
$\mathbf{\Sigma_{zx}}$	$\mathrm{E}(\mathbf{z}_i\mathbf{x}_i')$	$K \times L$
$\mathbf{S_{zx}}$	$\frac{1}{n}\mathbf{Z}'\mathbf{X}$	$K \times L$
$\mathbf{S}$	$\mathrm{E}(\mathbf{g}_i\mathbf{g}_i') = \mathrm{Avar}(\bar{\mathbf{g}})$	$K \times K$
$\widehat{\mathbf{S}}$	estimador consistente de $\mathbf{S}$	$K \times K$

Regra prática: $\mathbf{\Sigma}$ com letra grega = objeto *populacional*; $\mathbf{S}$ com letra latina = *análogo amostral*.

Atenção – notação do Hayashi (cap. 3)

Hayashi chama de $\mathbf{x}_i$ o que aqui é $\mathbf{z}_i$ (instrumentos), e de $\mathbf{z}_i$ o que aqui é $\mathbf{x}_i$ (regressores). Todas as fórmulas são equivalentes após a troca de letras.

Definição Formal do Estimador GMM

Seja $\widehat{\mathbf{W}}$ uma matriz $K \times K$ simétrica, positiva definida, tal que $\widehat{\mathbf{W}} \xrightarrow{p} \mathbf{W}$ (simétrica e positiva definida).

Definição (Estimador GMM)

$$\hat{\delta}(\widehat{\mathbf{W}}) \equiv \arg\min_{\tilde{\delta}} J(\tilde{\delta}, \widehat{\mathbf{W}}), \qquad J(\tilde{\delta}, \widehat{\mathbf{W}}) \equiv n \cdot \mathbf{g}_n(\tilde{\delta})' \widehat{\mathbf{W}} \mathbf{g}_n(\tilde{\delta}).$$

Caso linear (IV): quando $g_i(\delta) = \mathbf{z}_i(y_i - \mathbf{x}_i'\delta)$, os momentos amostrais são lineares em $\boldsymbol{\delta}$:

$$\mathbf{g}_n(\tilde{\delta}) = \mathbf{s}_{\mathbf{zy}} - \mathbf{S}_{\mathbf{zx}}\tilde{\delta},$$

e o critério J é quadrático em $\tilde{\boldsymbol{\delta}}$, admitindo solução analítica (ver Aula 2).

Consistência do Estimador GMM

Proposição (Consistência – Hayashi 3.1)

Sob condições de regularidade (ergodicidade estacionária, condição de posto, identificação global), para qualquer $\widehat{\mathbf{W}}$ positivo definido:

$$\hat{\boldsymbol{\delta}}(\widehat{\mathbf{W}}) \xrightarrow{p} \boldsymbol{\delta}_0.$$

- A prova usa: (i) LGN ($\mathbf{g}_n(\delta) \xrightarrow{p} \mathbf{0}$ somente em δ_0), (ii) que $\mathbf{W}$ é positiva definida (logo J só é zero em δ_0).
- A consistência **não depende** da escolha de $\widehat{\mathbf{W}}$; esta afeta apenas a eficiência.

A Condição MDS

Para a normalidade assintótica precisamos que os momentos $\mathbf{g}_i(\delta_0)$ obedeçam um TCL. A hipótese central é:

Hipótese (Hayashi 3.2): Sequência de Diferenças em Martingale

$\mathbf{g}_i(\delta_0) = \mathbf{z}_i\varepsilon_i$ é uma MDS com segundos momentos finitos:

$$\mathrm{E}(\mathbf{g}_i \mid \mathbf{g}_{i-1}, \mathbf{g}_{i-2}, \ldots) = \mathbf{0}.$$

Intuição: o resíduo ε_i é ortogonal *não apenas* aos instrumentos contemporâneos, mas também aos instrumentos passados:

$$\mathrm{E}(\varepsilon_i \mid \mathbf{z}_i, \mathbf{z}_{i-1}, \ldots, \mathbf{z}_1) = 0.$$

Mais forte que exogeneidade contemporânea; mais fraco que exogeneidade estrita.

Sob MDS ergódica estacionária (TCL de Gordin):

$$\sqrt{n}\,\bar{\mathbf{g}}_n(\delta_0) \xrightarrow{d} N(\mathbf{0}, \mathbf{S}), \quad \mathbf{S} \equiv \mathrm{E}(\mathbf{g}_i\mathbf{g}_i').$$

Distribuição Limite do Estimador GMM

Defina o Jacobiano populacional das condições de momento:

$$\mathbf{\Sigma_D} \equiv \mathrm{E}\left[\frac{\partial g_i(\delta_0)}{\partial \delta'}\right] \quad (K \times L).$$

No caso linear IV: $\mathbf{\Sigma_D} = \mathbf{\Sigma_{zx}} = \mathrm{E}(\mathbf{z}_i \mathbf{x}_i')$.

Proposição (Normalidade Assintótica – Hayashi 3.2)

Sob a condição MDS e hipóteses de regularidade:

$$\sqrt{n}(\hat{\boldsymbol{\delta}}(\widehat{\mathbf{W}}) - \boldsymbol{\delta}_0) \xrightarrow{d} N(\mathbf{0}, \mathrm{Avar}(\hat{\boldsymbol{\delta}})),$$

onde

$$\mathrm{Avar}(\hat{\boldsymbol{\delta}}(\widehat{\mathbf{W}})) = (\mathbf{\Sigma_D'W\Sigma_D})^{-1}\mathbf{\Sigma_D'WSW\Sigma_D}(\mathbf{\Sigma_D'W\Sigma_D})^{-1}.$$

Fórmula *sanduíche* generalizada, válida para qualquer $\mathbf{W}$.

Estimador Consistente da Variância Assintótica

Substituindo os objetos populacionais pelos amostrais:

$$\widehat{\mathrm{Avar}}(\hat{\boldsymbol{\delta}}) = \left(\mathbf{S}_{\mathbf{D}}'\widehat{\mathbf{W}}\mathbf{S}_{\mathbf{D}}\right)^{-1}\mathbf{S}_{\mathbf{D}}'\widehat{\mathbf{W}}\widehat{\mathbf{S}}\widehat{\mathbf{W}}\mathbf{S}_{\mathbf{D}}\left(\mathbf{S}_{\mathbf{D}}'\widehat{\mathbf{W}}\mathbf{S}_{\mathbf{D}}\right)^{-1},$$

onde $\mathbf{S}_{\mathbf{D}}$ é o Jacobiano amostral avaliado em $\hat{\boldsymbol{\delta}}$ (no caso linear IV: $\mathbf{S}_{\mathbf{D}} = \mathbf{S}_{\mathbf{zx}} = \frac{1}{n}\mathbf{Z}'\mathbf{X}$).

Erros-padrão robustos:

$$SE_{\ell}^{*} = \sqrt{\frac{1}{n}\left[\widehat{\mathrm{Avar}}(\hat{\boldsymbol{\delta}})\right]_{\ell\ell}}.$$

Qual é a Melhor Matriz de Pesos?

Proposição (Escolha Ótima de $\mathbf{W}$ – Hayashi 3.5)

O limite inferior da variância assintótica dos estimadores GMM é $(\mathbf{\Sigma}_\mathbf{D}'\mathbf{S}^{-1}\mathbf{\Sigma}_\mathbf{D})^{-1}$. *Ele é atingido se e somente se* $\mathbf{W} = \mathbf{S}^{-1}$.

Prova (esboço): define-se $\mathbf{C} = \mathbf{S}^{1/2}\mathbf{W}\mathbf{\Sigma}_\mathbf{D}$ e $\mathbf{B} = \mathbf{S}^{-1/2}\mathbf{\Sigma}_\mathbf{D}$. Mostra-se que

$$\mathrm{Avar}(\hat{\boldsymbol{\delta}}(\mathbf{W})) - (\mathbf{\Sigma}_\mathbf{D}'\mathbf{S}^{-1}\mathbf{\Sigma}_\mathbf{D})^{-1} = \mathbf{MSM}' \succeq 0,$$

onde $\mathbf{M}$ se anula quando $\mathbf{W} = \mathbf{S}^{-1}$.

GMM Eficiente:

$$\hat{\boldsymbol{\delta}}\left(\widehat{\mathbf{S}}^{-1}\right), \qquad \widehat{\mathrm{Avar}}\left(\hat{\boldsymbol{\delta}}\left(\widehat{\mathbf{S}}^{-1}\right)\right) = \left(\mathbf{S}_\mathbf{D}'\widehat{\mathbf{S}}^{-1}\mathbf{S}_\mathbf{D}\right)^{-1}.$$

Procedimento GMM em Dois Passos

O GMM eficiente requer $\widehat{\mathbf{S}}$, que por sua vez requer resíduos $\hat{\varepsilon}_i$, que requerem um estimador consistente de δ. **Solução:** dois passos.

Passo 1: Escolha qualquer $\widehat{\mathbf{W}}_1$ positiva definida (e.g. $\widehat{\mathbf{W}}_1 = \mathbf{I}$ ou $\mathbf{S}_{\mathbf{zz}}^{-1}$). Obtenha $\hat{\boldsymbol{\delta}}^{(1)}$ e calcule a matriz $\hat{\mathbf{G}}^{(1)}$ $(n \times K)$ cuja i-ésima linha é $g_i(\hat{\boldsymbol{\delta}}^{(1)})'$. Estime:

$$\widehat{\mathbf{S}} = \frac{1}{n}\hat{\mathbf{G}}^{(1)\prime}\hat{\mathbf{G}}^{(1)}.$$

Passo 2: Use $\widehat{\mathbf{W}}_2 = \widehat{\mathbf{S}}^{-1}$ e minimize $J(\tilde{\boldsymbol{\delta}}, \widehat{\mathbf{S}}^{-1})$. O minimizador $\hat{\boldsymbol{\delta}}^{(2)}$ é o estimador GMM eficiente.

A Prop. 3.4 do Hayashi garante que $\widehat{\mathbf{S}}$ baseado em qualquer estimador consistente de δ é consistente para $\mathbf{S}$.

Estimação de $\mathbf{S}$ – Caso i.i.d.

$\mathbf{S} = \mathrm{E}(\mathbf{g}_i\mathbf{g}_i') = \mathrm{E}(\varepsilon_i^2\mathbf{z}_i\mathbf{z}_i')$.

Caso heteroscedástico (i.i.d.): defina $\hat{\mathbf{\Omega}} = \mathrm{diag}(\hat{\varepsilon}_1^2, \ldots, \hat{\varepsilon}_n^2)$, então:

$$\widehat{\mathbf{S}} = \frac{1}{n}\mathbf{Z}'\hat{\mathbf{\Omega}}\mathbf{Z}.$$

Caso especial – homocedasticidade condicional $\mathrm{E}(\varepsilon_i^2 \mid \mathbf{z}_i) = \sigma^2$:

$$\mathbf{S} = \sigma^2\mathbf{\Sigma}_{\mathbf{zz}}, \qquad \widehat{\mathbf{S}} = \hat{\sigma}^2\mathbf{S}_{\mathbf{zz}}.$$

Neste caso $\widehat{\mathbf{S}}$ *não* requer hipóteses sobre quartos momentos, o que melhora o comportamento em amostras pequenas.

Veremos na Aula 2 que, sob homocedasticidade, o GMM eficiente colapsa para o estimador de **Mínimos Quadrados em Dois Estágios (MQ2E)**.

Estimação de $\mathbf{S}$ – HAC (Séries Temporais)

Com dependência temporal, a variância assintótica de $\sqrt{n}\bar{\mathbf{g}}$ envolve todas as autocovariâncias:

$$\mathbf{S} = \sum_{j=-\infty}^{\infty} \boldsymbol{\Gamma}_j, \qquad \boldsymbol{\Gamma}_j = \mathrm{E}(\mathbf{g}_t \mathbf{g}_{t-j}').$$

Estimação por **kernel** (Heteroskedasticity and Autocorrelation Consistent):

$$\widehat{\mathbf{S}} = \sum_{j=-(n-1)}^{n-1} k\left(\frac{j}{q(n)}\right) \widehat{\boldsymbol{\Gamma}}_j, \qquad \widehat{\boldsymbol{\Gamma}}_j = \frac{1}{n} \sum_{t=j+1}^{n} \hat{\mathbf{g}}_t \hat{\mathbf{g}}_{t-j}',$$

Kernel	$k(x)$
Truncado	$\mathbf{1}(\lvert x\rvert \le 1)$
Bartlett (Newey-West)	$(1-\lvert x\rvert)\mathbf{1}(\lvert x\rvert \le 1)$ [garante $\widehat{\mathbf{S}} \succeq 0$]
Spectral Quadrático	$\frac{25}{12\pi^2 x^2}\left[\frac{\sin(6\pi x/5)}{6\pi x/5} - \cos(6\pi x/5)\right]$

Testes de Hipóteses com GMM

Com $\widehat{\mathrm{Avar}}(\hat{\boldsymbol{\delta}})$ estimado de forma consistente:

(a) Teste t: $H_0 : \delta_\ell = \bar{\delta}_\ell$

$$t_\ell = \frac{\hat{\delta}_\ell - \bar{\delta}_\ell}{SE^*_\ell} \xrightarrow{d} N(0,1).$$

(b) Wald linear: $H_0 : \mathbf{R}\boldsymbol{\delta} = \mathbf{r}$, $\mathbf{R}$ $(r \times L)$ posto linha pleno

$$W = n \cdot (\mathbf{R}\hat{\boldsymbol{\delta}} - \mathbf{r})' \left\{ \mathbf{R}\, \widehat{\mathrm{Avar}}(\hat{\boldsymbol{\delta}})\, \mathbf{R}' \right\}^{-1} (\mathbf{R}\hat{\boldsymbol{\delta}} - \mathbf{r}) \xrightarrow{d} \chi^2(r).$$

(c) Wald não linear: $H_0 : \mathbf{a}(\boldsymbol{\delta}) = \mathbf{0}$, $\mathbf{A}(\boldsymbol{\delta}) = \partial \mathbf{a} / \partial \boldsymbol{\delta}'$ posto linha pleno

$$W = n \cdot \mathbf{a}(\hat{\boldsymbol{\delta}})' \left\{ \mathbf{A}(\hat{\boldsymbol{\delta}})\, \widehat{\mathrm{Avar}}(\hat{\boldsymbol{\delta}})\, \mathbf{A}(\hat{\boldsymbol{\delta}})' \right\}^{-1} \mathbf{a}(\hat{\boldsymbol{\delta}}) \xrightarrow{d} \chi^2(\#\mathbf{a}).$$

LR-GMM

Análogo do LR para GMM, usando a função critério J com $\widehat{\mathbf{W}} = \widehat{\mathbf{S}}^{-1}$:

$$LR_{\text{GMM}} \equiv J\big(\bar{\boldsymbol{\delta}}, \widehat{\mathbf{S}}^{-1}\big) - J\big(\hat{\boldsymbol{\delta}}, \widehat{\mathbf{S}}^{-1}\big) \xrightarrow{d} \chi^2(r),$$

onde $\bar{\boldsymbol{\delta}}$ é o minimizador restrito de J sob H_0 e r é o número de restrições.

Intuição: se H_0 for verdadeira, impor a restrição não deve elevar muito o valor mínimo da função critério.

Teste de Hansen – Restrições Sobreidentificadoras

- Com $K = L$: sempre existe $\tilde{\delta}$ que zera $\mathbf{g}_n = \mathbf{0} \Rightarrow J_{\min} = 0$. Não há nada a testar.
- Com $K > L$: $J_{\min} > 0$. Se as condições de momento forem verdadeiras, $J_{\min}$ deve ser *pequeno*.

Proposição (Hansen (1982) – Hayashi 3.6)

Seja $\widehat{\mathbf{S}}$ *consistente para* $\mathbf{S}$. *Sob* H_0: *"todas as* K *condições de momento são válidas":*

$$J\left(\hat{\delta}\left(\widehat{\mathbf{S}}^{-1}\right), \widehat{\mathbf{S}}^{-1}\right) \xrightarrow{d} \chi^2(K-L).$$

Os $K - L$ graus de liberdade refletem as restrições sobreidentificadoras: K condições para L parâmetros $\Rightarrow$ $K - L$ condições "a mais".

C-Test – Validade de um Subconjunto de Instrumentos

Proposição (Teste C (Diferença de Sargan) – Hayashi 3.7)

Particione $\mathbf{z}_i = (\mathbf{z}_{i1}', \mathbf{z}_{i2}')'$ *onde* $\mathbf{z}_{i2}$ *(*K_2 *instrumentos) são "confiáveis" e* $\mathbf{z}_{i1}$ *(*$K_1 = K - K_2$ *instrumentos) são "suspeitos". Sejam* J *e* J_2 *os testes de Hansen com o conjunto completo e apenas* $\mathbf{z}_{i2}$*, respectivamente. Então, sob* H_0*: "*$\mathbf{z}_{i1}$ *são válidos":*

$$C \equiv J - J_2 \xrightarrow{d} \chi^2(K_1).$$

- Exige que $\mathbf{z}_{i2}$ sozinhos satisfaçam a condição de posto.
- Equivalente ao teste de Hausman instrumentado.
- Sob homocedasticidade, C coincide com a diferença das estatísticas de Sargan.

GMM em Amostras Finitas

- As propriedades ótimas do GMM eficiente são **assintóticas**. Em amostras pequenas, há evidências de distorções importantes.
- O GMM eficiente usa $\widehat{\mathbf{S}}^{-1}$, que envolve *quartos momentos* estimados – fonte adicional de variabilidade em amostras finitas.
- A edição especial do *JBES* (julho/1996) documentou:
  - O GMM com $\widehat{\mathbf{W}} = \mathbf{I}$ (pesos iguais) frequentemente domina o GMM eficiente em termos de viés e variância em amostras finitas.
  - A estatística de Wald **sobre-rejeita** H_0 em amostras pequenas (tamanho real $\gg$ tamanho nominal).
- **Alternativas:** GMM Contínuo-Atualizado (CUE) de Hansen, Heaton e Yaron (1996); bootstrap das estatísticas de teste.