

GMM - Parte II

Bibliografia: Hayashi, cap. 3

Claudio Lucinda

FEA/USP



Overview

- 1 Weighting Matrix
 - Efficient 2Step GMM
 - Considerações de Amostra Pequena
- 2 Testando Restrições Sobre-Identificadoras
- 3 Implicações de Homocedasticidade
 - HAC GMM



GMM em 2 estágios

Naturalmente, desejamos escolher entre os estimadores GMM indexados por $\widehat{\mathbf{W}}$ aquele que tiver a menor variância assintótica. A próxima proposição fornece uma escolha de \mathbf{W} que minimiza a variância assintótica.

Proposition

Proposição 3.5 (escolha ótima da matriz de ponderação): Um limite inferior para a variância assintótica dos estimadores GMM indexados por $\widehat{\mathbf{W}}$ é dado por $(\boldsymbol{\Sigma}'_{xz} \mathbf{S}^{-1} \boldsymbol{\Sigma}_{xz})^{-1}$. O limite inferior é alcançado se $\widehat{\mathbf{W}}$ for tal que $\mathbf{W}(\equiv \text{plim } \widehat{\mathbf{W}}) = \mathbf{S}^{-1}$

Como a variância assintótica para qualquer $\widehat{\mathbf{W}}$ é (3.5.1), essa proposição é provada se pudermos mostrar que

$$(\boldsymbol{\Sigma}'_{xz} \mathbf{W} \boldsymbol{\Sigma}_{xz})^{-1} \boldsymbol{\Sigma}'_{xz} \mathbf{W} \mathbf{S} \mathbf{W} \boldsymbol{\Sigma}_{xz} (\boldsymbol{\Sigma}'_{xz} \mathbf{W} \boldsymbol{\Sigma}_{xz})^{-1} \geq (\boldsymbol{\Sigma}'_{xz} \mathbf{S}^{-1} \boldsymbol{\Sigma}_{xz})^{-1}$$



Estimador GMM Eficiente

$$\hat{\delta} \left(\hat{\mathbf{S}}^{-1} \right) = \left(\mathbf{s}'_{xz} \hat{\mathbf{S}}^{-1} \mathbf{s}_{xz} \right)^{-1} \mathbf{s}'_{xz} \hat{\mathbf{S}}^{-1} \mathbf{s}_{xy},$$

$$\text{Avar} \left(\hat{\delta} \left(\hat{\mathbf{S}}^{-1} \right) \right) = \left(\boldsymbol{\Sigma}'_{xz} \mathbf{S}^{-1} \boldsymbol{\Sigma}_{xz} \right)^{-1}$$

$$\text{Avar} \left(\hat{\delta} \left(\hat{\mathbf{S}}^{-1} \right) \right) = \left(\mathbf{s}'_{xz} \hat{\mathbf{S}}^{-1} \mathbf{s}_{xz} \right)^{-1}$$

Teste t e Wald GMM Eficiente

Com $\widehat{\mathbf{W}} = \widehat{\mathbf{S}}^{-1}$, as fórmulas pra estatística t e teste Wald ficam

$$t_{\ell} = \frac{\hat{\delta}_{\ell} \left(\widehat{\mathbf{S}}^{-1} \right) - \bar{\delta}_{\ell}}{SE_{\ell}^*}$$

em que SE_{ℓ}^* é o erro-padrão robusto dado por

$$SE_{\ell}^* = \sqrt{\frac{1}{n} \cdot \left(\left(\mathbf{S}_{xz}' \widehat{\mathbf{S}}^{-1} \mathbf{S}_{xz} \right)^{-1} \right)_{\ell\ell}}$$

e

$$W = n \cdot \mathbf{a} \left(\hat{\delta} \left(\widehat{\mathbf{S}}^{-1} \right) \right)' \left\{ \mathbf{A} \left(\hat{\delta} \left(\widehat{\mathbf{S}}^{-1} \right) \right) \left(\mathbf{S}_{xz}' \widehat{\mathbf{S}}^{-1} \mathbf{S}_{xz} \right)^{-1} \mathbf{A} \left(\hat{\delta} \left(\widehat{\mathbf{S}}^{-1} \right) \right)' \right\}^{-1} \mathbf{a} \left(\hat{\delta} \left(\widehat{\mathbf{S}}^{-1} \right) \right)$$



GMM em duas etapas

Para calcular o estimador GMM eficiente, precisamos do estimador consistente $\widehat{\mathbf{S}}$. Mas a Proposição 3.4 do livro nos garante que o $\widehat{\mathbf{S}}$ baseado em qualquer estimador consistente de δ é consistente para \mathbf{S} . Isso nos leva ao seguinte procedimento GMM eficiente em duas etapas:

Passo 1: Escolha uma matriz $\widehat{\mathbf{W}}$ que converja em probabilidade para uma matriz definida simétrica e positiva, e minimize $J(\tilde{\delta}, \widehat{\mathbf{W}})$ sobre $\tilde{\delta}$ para obter $\widehat{\delta}(\widehat{\mathbf{W}})$. Não faltam tais matrizes $\widehat{\mathbf{W}}$ (por exemplo, $\widehat{\mathbf{W}} = \mathbf{I}$), mas geralmente definimos $\widehat{\mathbf{W}} = \mathbf{S}_{xx}^{-1}$. O estimador resultante $\widehat{\delta}(\mathbf{S}_{xx}^{-1})$ é o celebrado mínimo quadrado de dois estágios. Use isso para calcular o resíduo $\widehat{\varepsilon}_i \equiv y_i - \mathbf{z}_i' \widehat{\delta}(\widehat{\mathbf{W}})$ e obter um estimador consistente $\widehat{\mathbf{S}}$ de \mathbf{S} por (3.5.10),

Passo 2: Minimize $J(\tilde{\delta}, \widehat{\mathbf{S}}^{-1})$ em termos de $\tilde{\delta}$. O valor que minimiza é o estimador GMM eficiente.



Amostra Pequena

- Essas propriedades assintóticas desejáveis do estimador GMM eficiente e estatísticas de teste associadas são transportadas para suas distribuições de amostras finitas? O estimador GMM eficiente usa $\hat{\mathbf{S}}^{-1}$, uma função dos quartos momentos estimados, para $\widehat{\mathbf{W}}$.
- Esperaríamos que o estimador GMM eficiente tivesse propriedades de amostra pequena mais pobres do que os estimadores GMM que não usam quartos momentos para $\widehat{\mathbf{W}}$.
- A edição de julho de 1996 do JBES tem vários artigos examinando a distribuição de pequenas amostras de estimadores GMM e estatísticas de teste associadas para vários DGPs. Sua conclusão geral é que o estimador GMM igualmente ponderado com $\widehat{\mathbf{W}} = \mathbf{I}$ geralmente supera o GMM eficiente em termos de viés e variância em amostras finitas.
- Se α é o nível de significância assumido e c_α é o valor crítico associado para que $\text{Prob}(\chi^2 > c_\alpha) = \alpha$, a probabilidade em amostras finitas de que a estatística de Wald seja maior que c_α excede em muito α ; o teste rejeita o nulo com muita frequência.



Testando Restrições Sobre-Identificadoras

Se a equação for exatamente identificada, então é possível escolher $\tilde{\delta}$ para que todos os elementos dos momentos amostrais $\mathbf{g}_n(\tilde{\delta})$ são zero e a distância

$$J(\tilde{\delta}, \widehat{\mathbf{W}}) \equiv n \cdot \mathbf{g}_n(\tilde{\delta})' \widehat{\mathbf{W}} \mathbf{g}_n(\tilde{\delta})$$

é zero. (O $\tilde{\delta}$ que faz isso é o estimador IV.) Se a equação for sobreidentificada, então a distância não pode ser definida exatamente como zero, mas esperamos que a distância minimizada seja próxima a zero. Acontece que, se a matriz de ponderação $\widehat{\mathbf{W}}$ for escolhida de forma ótima para que $\text{plim } \widehat{\mathbf{W}} = \mathbf{S}^{-1}$, então a distância minimizada é assintoticamente qui-quadrada.



Testando Restrições Sobre-Identificadoras

Seja $\hat{\mathbf{S}}$ um estimador consistente de \mathbf{S} , e considere primeiro o caso em que a distância é avaliada no verdadeiro valor do parâmetro δ , $J(\delta, \hat{\mathbf{S}}^{-1})$. Já que por definição $\mathbf{g}_n(\tilde{\delta}) = \bar{\mathbf{g}} (\equiv \frac{1}{n} \sum_i \mathbf{g}_i)$ para $\tilde{\delta} = \delta$, a distância é igual a

$$J(\delta, \hat{\mathbf{S}}^{-1}) = n \cdot \bar{\mathbf{g}}' \hat{\mathbf{S}}^{-1} \bar{\mathbf{g}} = (\sqrt{n} \bar{\mathbf{g}})' \hat{\mathbf{S}}^{-1} (\sqrt{n} \bar{\mathbf{g}})$$

Proposition

Proposition 3.6 (Teste de Hansen sobre restrições sobreidentificadoras (Hansen, 1982)): Suponha um estimador consistente, $\hat{\mathbf{S}}$, de $\mathbf{S} (= E(\mathbf{g}_i \mathbf{g}_i'))$. Sob algumas premissas,

$$J(\hat{\delta}(\hat{\mathbf{S}}^{-1}), \hat{\mathbf{S}}^{-1}) \left(= n \cdot \mathbf{g}_n(\hat{\delta}(\hat{\mathbf{S}}^{-1}))' \hat{\mathbf{S}}^{-1} \mathbf{g}_n(\hat{\delta}(\hat{\mathbf{S}}^{-1})) \right) \xrightarrow{d} \chi^2(K - L)$$



Testando Condições de Ortogonalidade

Proposition

Proposição 3.7 (testando um subconjunto de condições de ortogonalidade): Seja \mathbf{x}_{i1} um subvetor de \mathbf{x}_i e fortaleça a Suposição 3.4 exigindo que a condição de posto para identificação seja satisfeita para \mathbf{x}_{i1} (então $E(\mathbf{x}_{i1}\mathbf{z}'_i)$ é de posto coluna cheio). Então, para quaisquer estimadores consistentes $\hat{\mathbf{S}}$ de \mathbf{S} e $\hat{\mathbf{S}}_{11}$ de \mathbf{S}_{11} ,

$$C \equiv J - J_1 \xrightarrow{d} \chi^2(K - K_1)$$

onde $K = \#\mathbf{x}_i$ (dimensão de \mathbf{x}_i), $K_1 = \#\mathbf{x}_{i1}$ (dimensão de \mathbf{x}_{i1}), e J e J_1 são as estatísticas de Hansen para o modelo com todas e o modelo só com um subconjunto de restrições.



Homocedasticidade

Assumindo:

$$E(\varepsilon_i^2 \mid \mathbf{x}_i) = \sigma^2$$

Sob homocedasticidade condicional, a matriz de quartos momentos \mathbf{S} ($= E(\mathbf{g}_i \mathbf{g}_i') = E(\varepsilon_i^2 \mathbf{x}_i \mathbf{x}_i')$) pode ser escrito como um produto de segundos momentos:

$$\mathbf{S} = \sigma^2 \boldsymbol{\Sigma}_{\mathbf{xx}}$$

Em que $\boldsymbol{\Sigma}_{\mathbf{xx}} = E(\mathbf{x}_i \mathbf{x}_i')$.



Homocedasticidade

O estimador de \mathbf{S} sob esta premissa é

$$\hat{\mathbf{S}} = \hat{\sigma}^2 \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' = \hat{\sigma}^2 \mathbf{S}_{xx}$$

onde $\hat{\sigma}^2$ é algum estimador consistente a ser especificado abaixo. Pela estacionariedade ergódica, $\mathbf{S}_{xx} \rightarrow_{a.s.} \mathbf{\Sigma}_{xx}$. Assim, desde que $\hat{\sigma}^2$ seja consistente, não precisamos premissas sobre os quartos momentos para que $\hat{\mathbf{S}}$ seja consistente.



GMM Eficiente vira MQ2E (e IV)

Como vimos na estimação eficiente de GMM, a matriz de ponderação é $\hat{\mathbf{S}}^{-1}$. Usando o estimador do slide anterior $\hat{\mathbf{S}}$ isso fica

$$\begin{aligned}\hat{\delta} \left(\hat{\mathbf{S}}^{-1} \right) &= \left[\mathbf{S}'_{xz} \left(\hat{\sigma}^2 \mathbf{S}_{xx} \right)^{-1} \mathbf{S}_{xz} \right]^{-1} \mathbf{S}'_{xz} \left(\hat{\sigma}^2 \mathbf{S}_{xx} \right)^{-1} \mathbf{S}_{xy} \\ &= \left(\mathbf{S}'_{xz} \mathbf{S}_{xx}^{-1} \mathbf{S}_{xz} \right)^{-1} \mathbf{S}'_{xz} \mathbf{S}_{xx}^{-1} \mathbf{S}_{xy} \\ &= \hat{\delta} \left(\mathbf{S}_{xx}^{-1} \right) \equiv \hat{\delta}_{2SLS}\end{aligned}$$

A expressão para $\text{Avar} \left(\hat{\delta}_{2SLS} \right)$ é:

$$\text{Avar} \left(\hat{\delta}_{2SLS} \right) = \sigma^2 \cdot \left(\boldsymbol{\Sigma}'_{xz} \boldsymbol{\Sigma}_{xx}^{-1} \boldsymbol{\Sigma}_{xz} \right)^{-1}$$

Com o estimador:

$$\text{Avar} \left(\hat{\delta}_{2SLS} \right) = \hat{\sigma}^2 \cdot \left(\mathbf{S}'_{xz} \mathbf{S}_{xx}^{-1} \mathbf{S}_{xz} \right)^{-1}$$



Sargan e Hansen

Um outro teste de restrições sobre-identificadoras é o Teste de Sargan - basicamente é n multiplicado pelo R^2 dos resíduos da regressão estimada por IV contra as variáveis exógenas. Sob homocedasticidade, a gente mostra que isso é igual ao nosso teste de Hansen:

Quando $\widehat{\mathbf{W}}$ é definido como sendo $(\hat{\sigma}^2 \mathbf{S}_{xx})^{-1}$, a função critério GMM se torna:

$$J\left(\tilde{\delta}, (\hat{\sigma}^2 \cdot \mathbf{S}_{xx})^{-1}\right) = n \cdot \frac{\left(\mathbf{S}_{xy} - \mathbf{S}_{xz}\tilde{\delta}\right)' \mathbf{S}_{xx}^{-1} \left(\mathbf{S}_{xy} - \mathbf{S}_{xz}\tilde{\delta}\right)}{\hat{\sigma}^2}$$

Que é a estatística de Sargan



HAC GMM

- E quando não temos motivo para assumir a homocedasticidade?
- Aí precisamos construir a matriz de pesos que seja sobusta a heterocedasticidade - e autocorrelação
- Se sabemos a priori que $\mathbf{\Gamma}_j = \mathbf{0}$ para $j > q$ em que q é conhecido e finito, então claramente \mathbf{S} pode ser estimado por

$$\hat{\mathbf{S}} = \hat{\mathbf{\Gamma}}_0 + \sum_{j=1}^q \left(\hat{\mathbf{\Gamma}}_j + \hat{\mathbf{\Gamma}}_j' \right) = \sum_{j=-q}^q \hat{\mathbf{\Gamma}}_j \quad \left(\text{assumindo: } \hat{\mathbf{\Gamma}}_{-j} = \hat{\mathbf{\Gamma}}_j' \right).$$

$$\hat{\mathbf{\Gamma}}_j = \frac{1}{n} \sum_{t=j+1}^n \hat{\mathbf{g}}_t \hat{\mathbf{g}}_{t-j}' \quad (j = 0, 1, \dots, n-1)$$

e

$$\hat{\mathbf{g}}_t \equiv \mathbf{x}_t \cdot \hat{\varepsilon}_t, \quad \hat{\varepsilon}_t = y_t - \mathbf{z}_t' \hat{\boldsymbol{\delta}}, \quad \hat{\boldsymbol{\delta}} \text{ consistente para } \boldsymbol{\delta}.$$



Usando Kernels para estimar S

Uma classe de estimadores, chamados de baseados em kernels (ou "não paramétricos") podem ser expressos como uma média ponderada das autocovariâncias estimadas:

$$\hat{\mathbf{S}} = \sum_{j=-n+1}^{n-1} k\left(\frac{j}{q(n)}\right) \cdot \hat{\mathbf{r}}_j$$

A função $k(\cdot)$ é chamada de kernel, e $q(n)$, bandwidth. O do slide anterior é um exemplo de kernel truncado, com $q(n) = q$

$$k(x) = \begin{cases} 1 & \text{for } |x| \leq 1 \\ 0 & \text{for } |x| > 1 \end{cases}$$



Kernel de Bartlett e Spectral Quadrático

Newey e West (1987) observaram que o estimador baseado em kernel pode ser definido como não negativo em amostras finitas se o kernel for o kernel de Bartlett:

$$k(x) = \begin{cases} 1 - |x| & \text{for } |x| \leq 1 \\ 0 & \text{for } |x| > 1 \end{cases}$$

O estimador baseado no kernel de Bartlett de S é chamado (em econometria) de estimador Newey-West. Por exemplo, para $q(n) = 3$, o estimador baseado em kernel inclui autocovariâncias de até dois (não três) lags:

$$\hat{\mathbf{S}} = \hat{\mathbf{r}}_0 + \left(\frac{2}{3}\right) (\hat{\mathbf{r}}_1 + \hat{\mathbf{r}}_1') + \left(\frac{1}{3}\right) (\hat{\mathbf{r}}_2 + \hat{\mathbf{r}}_2')$$

Outro exemplo é o Spectral Quadrático

$$k(x) = \frac{25}{12\pi^2 x^2} \left(\frac{\sin(6\pi x/5)}{6\pi x/5} - \cos(6\pi x/5) \right).$$

Uma vez que $k(x) \neq 0$ for $|x| > 1$ aqui, todas as autocovariâncias estimadas $\hat{\Gamma}_j$ ($j = 0, 1, \dots, n-1$) entram no cálculo de $\hat{\mathbf{S}}$ mesmo se $q(n) < n-1$.

