GMM – Parte II

GMM Linear e Variáveis Instrumentais

Claudio Lucinda

FEA/USP

Overview

1. O Modelo Linear com Instrumentos
2. Condições de Identificação
3. O Estimador GMM Linear
4. Caso Exatamente Identificado: Estimador IV
5. Caso Sobreidentificado: MQ2E como GMM Eficiente
6. GMM Robusto no Modelo Linear
7. Testes no Modelo Linear

Setup: Modelo Linear com Variáveis Endógenas

Considere o modelo de regressão linear:

$$y_i = \mathbf{x}_i'\boldsymbol{\delta} + \varepsilon_i, \qquad i = 1, \ldots, n,$$

onde $\mathbf{x}_i$ $(L \times 1)$ pode ser **endógeno**: $\mathrm{E}(\mathbf{x}_i\varepsilon_i) \neq \mathbf{0}$.

Instrumentos: existe um vetor $\mathbf{z}_i$ $(K \times 1)$ de variáveis *predeterminadas* tal que

$$\mathrm{E}(\mathbf{z}_i\varepsilon_i) = \mathbf{0}.$$

As condições de momento do GMM são portanto:

$$\mathbf{g}_i(\boldsymbol{\delta}) \equiv \mathbf{z}_i\varepsilon_i = \mathbf{z}_i(y_i - \mathbf{x}_i'\boldsymbol{\delta}), \qquad \mathrm{E}[\mathbf{g}_i(\boldsymbol{\delta}_0)] = \mathbf{0}.$$

Nota de Notação – Hayashi Cap. 3

Hayashi chama de $\mathbf{x}_i$ o que aqui é $\mathbf{z}_i$ (instrumentos) e de $\mathbf{z}_i$ o que aqui é $\mathbf{x}_i$ (regressores). Esta é a única diferença em relação ao livro.

Partição dos Regressores e Instrumentos

É útil particionar $\mathbf{x}_i$ em duas partes:

$$\mathbf{x}_i = \begin{pmatrix} \mathbf{x}_i^{ex} \\ \mathbf{x}_i^{en} \end{pmatrix} \quad \begin{cases} \mathbf{x}_i^{ex}: & L_1 \text{ regressores exógenos (predeterminados)} \\ \mathbf{x}_i^{en}: & L_2 \text{ regressores endógenos} \end{cases} \qquad L = L_1 + L_2.$$

O vetor de instrumentos $\mathbf{z}_i$ $(K \times 1)$ inclui:

- Os próprios regressores exógenos $\mathbf{x}_i^{ex}$ ("instrumentos internos").
- $K - L_1$ variáveis **externas** excluídas da equação estrutural.

A condição $\mathrm{E}(\mathbf{z}_i \varepsilon_i) = \mathbf{0}$ exige em particular que os regressores endógenos *não* façam parte de $\mathbf{z}_i$.

Condição de Ordem

Condição de Ordem (necessária)

$$K \geq L \quad \Leftrightarrow \quad \underbrace{K - L_1}_{\text{instrumentos externos}} \geq \underbrace{L_2}_{\text{regressores endógenos}} .$$

- $K = L$: equação **exatamente identificada**.
- $K > L$: equação **sobreidentificada** — informação extra que pode ser usada para ganhar eficiência e testar validade dos instrumentos.
- $K < L$: equação **subidentificada** — não estimável por IV/GMM.

A condição de ordem é *necessária* mas não suficiente. A condição suficiente é a condição de posto.

Condição de Posto

Condição de Posto (necessária e suficiente – Hayashi Hip. 3.4)

A matriz $K \times L$

$$\boldsymbol{\Sigma}_{\mathbf{zx}} \equiv \mathrm{E}(\mathbf{z}_i \mathbf{x}_i')$$

tem posto coluna pleno: $\mathrm{rank}(\boldsymbol{\Sigma}_{\mathbf{zx}}) = L$.

Intuição: as condições de momento populacionais formam o sistema linear

$$\boldsymbol{\Sigma}_{\mathbf{zx}}\, \boldsymbol{\delta} = \boldsymbol{\sigma}_{\mathbf{z}y}, \qquad \boldsymbol{\sigma}_{\mathbf{z}y} \equiv \mathrm{E}(\mathbf{z}_i y_i).$$

Para que exista solução única, $\boldsymbol{\Sigma}_{\mathbf{zx}}$ precisa ter posto coluna L.

A condição de posto falha quando os instrumentos são **fracos** — fracamente correlacionados com os regressores endógenos.

Função Critério no Caso Linear

Com $\mathbf{g}_i(\boldsymbol{\delta}) = \mathbf{z}_i(y_i - \mathbf{x}_i'\boldsymbol{\delta})$, o vetor de momentos amostrais escreve-se em forma matricial como:

$$\mathbf{g}_n(\tilde{\boldsymbol{\delta}}) = \frac{1}{n}\mathbf{Z}'(\mathbf{y} - \mathbf{X}\tilde{\boldsymbol{\delta}}) = \underbrace{\frac{1}{n}\mathbf{Z}'\mathbf{y}}_{\mathbf{s}_{zy}} - \underbrace{\frac{1}{n}\mathbf{Z}'\mathbf{X}}_{\mathbf{S}_{zx}}\tilde{\boldsymbol{\delta}}.$$

A função critério é quadrática em $\tilde{\boldsymbol{\delta}}$:

$$J(\tilde{\boldsymbol{\delta}}, \widehat{\mathbf{W}}) = n \cdot (\mathbf{s}_{zy} - \mathbf{S}_{zx}\tilde{\boldsymbol{\delta}})'\widehat{\mathbf{W}}(\mathbf{s}_{zy} - \mathbf{S}_{zx}\tilde{\boldsymbol{\delta}}).$$

Minimizando em $\tilde{\boldsymbol{\delta}}$ (CPO: $\partial J/\partial\tilde{\boldsymbol{\delta}} = \mathbf{0}$):

$$\boxed{\hat{\boldsymbol{\delta}}(\widehat{\mathbf{W}}) = \left(\mathbf{S}_{zx}'\widehat{\mathbf{W}}\mathbf{S}_{zx}\right)^{-1}\mathbf{S}_{zx}'\widehat{\mathbf{W}}\,\mathbf{s}_{zy}.}$$

Variância Assintótica no Caso Linear

Da Aula 1, com $\mathbf{\Sigma_D} = \mathbf{\Sigma_{zx}}$ e $\mathbf{S_D} = \mathbf{S_{zx}} = \frac{1}{n}\mathbf{Z'X}$:

$$\operatorname{Avar}(\hat{\boldsymbol{\delta}}(\widehat{\mathbf{W}})) = (\mathbf{\Sigma}'_{\mathbf{zx}}\mathbf{W}\mathbf{\Sigma}_{\mathbf{zx}})^{-1}\mathbf{\Sigma}'_{\mathbf{zx}}\mathbf{W}\mathbf{S}\mathbf{W}\mathbf{\Sigma}_{\mathbf{zx}}(\mathbf{\Sigma}'_{\mathbf{zx}}\mathbf{W}\mathbf{\Sigma}_{\mathbf{zx}})^{-1},$$

onde $\mathbf{S} = \mathrm{E}(\varepsilon_i^2\mathbf{z}_i\mathbf{z}_i') = \frac{1}{n}\mathbf{Z'\Omega Z}$ em notação populacional.

Estimador consistente (fórmula sanduíche):

$$\widehat{\operatorname{Avar}}(\hat{\boldsymbol{\delta}}) = (\mathbf{S}'_{\mathbf{zx}}\widehat{\mathbf{W}}\mathbf{S}_{\mathbf{zx}})^{-1}\mathbf{S}'_{\mathbf{zx}}\widehat{\mathbf{W}}\widehat{\mathbf{S}}\widehat{\mathbf{W}}\mathbf{S}_{\mathbf{zx}}(\mathbf{S}'_{\mathbf{zx}}\widehat{\mathbf{W}}\mathbf{S}_{\mathbf{zx}})^{-1}.$$

IV Clássico ($K = L$)

Quando $K = L$, $\mathbf{S_{zx}} = \frac{1}{n}\mathbf{Z}'\mathbf{X}$ é quadrada e invertível (pela condição de posto). Existe $\tilde{\boldsymbol{\delta}}$ que zera *exatamente* todos os momentos amostrais:

$$\mathbf{S_{zx}}\tilde{\boldsymbol{\delta}} = \mathbf{s}_{zy} \quad \Rightarrow \quad \hat{\boldsymbol{\delta}}_{IV} = \mathbf{S_{zx}}^{-1}\mathbf{s}_{zy} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\mathbf{y}.$$

Note que neste caso a solução **não depende** de $\widehat{\mathbf{W}}$: qualquer matriz de pesos leva ao mesmo estimador.

Variância assintótica:

$$\operatorname{Avar}(\hat{\boldsymbol{\delta}}_{IV}) = \boldsymbol{\Sigma}_{\mathbf{zx}}^{-1}\,\mathbf{S}\,(\boldsymbol{\Sigma}_{\mathbf{zx}}')^{-1}.$$

Sob homocedasticidade ($\mathbf{S} = \sigma^2\boldsymbol{\Sigma}_{\mathbf{zz}}$), esta simplifica para $\sigma^2(\boldsymbol{\Sigma}_{\mathbf{zx}}'\boldsymbol{\Sigma}_{\mathbf{zx}}^{-1}\boldsymbol{\Sigma}_{\mathbf{zx}})^{-1}$.

Homocedasticidade e a Forma de **S**

Assuma homocedasticidade condicional:

$$\mathrm{E}(\varepsilon_i^2 \mid \mathbf{z}_i) = \sigma^2.$$

Então:

$$\mathbf{S} = \mathrm{E}(\varepsilon_i^2 \mathbf{z}_i \mathbf{z}_i') = \sigma^2 \, \mathrm{E}(\mathbf{z}_i \mathbf{z}_i') = \sigma^2 \, \boldsymbol{\Sigma}_{\mathbf{zz}}.$$

A **matriz de pesos ótima** é:

$$\mathbf{W}^* = \mathbf{S}^{-1} = \frac{1}{\sigma^2} \boldsymbol{\Sigma}_{\mathbf{zz}}^{-1}.$$

Como σ^2 é um escalar positivo, ele cancela na fórmula do estimador. Podemos tomar $\widehat{\mathbf{W}} = \mathbf{S}_{\mathbf{zz}}^{-1} = \left(\frac{1}{n}\mathbf{Z}'\mathbf{Z}\right)^{-1}$.

MQ2E como GMM Eficiente sob Homocedasticidade

Substituindo $\widehat{\mathbf{W}} = \mathbf{S}_{\mathbf{zz}}^{-1} = \left(\frac{1}{n}\mathbf{Z}'\mathbf{Z}\right)^{-1}$ na fórmula geral e simplificando os fatores $1/n$:

$$\hat{\delta}(\mathbf{S}_{\mathbf{zz}}^{-1}) = \left[\mathbf{X}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{X}\right]^{-1}\mathbf{X}'\mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{y} = \left(\mathbf{X}'\mathbf{P}_{\mathbf{Z}}\mathbf{X}\right)^{-1}\mathbf{X}'\mathbf{P}_{\mathbf{Z}}\mathbf{y} \;\equiv\; \hat{\delta}_{2SLS},$$

onde $\mathbf{P}_{\mathbf{Z}} = \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'$ é o projetor ortogonal no espaço coluna de $\mathbf{Z}$.

Conclusão: sob homocedasticidade condicional, o **MQ2E** é o GMM eficiente.

Interpretação em Dois Estágios

A fórmula $\hat{\boldsymbol{\delta}}_{2SLS} = (\mathbf{X}'\mathbf{P}_{\mathbf{Z}}\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_{\mathbf{Z}}\mathbf{y}$ admite interpretação em dois estágios:

1º Estágio: projete $\mathbf{X}$ no espaço de $\mathbf{Z}$:

$$\widehat{\mathbf{X}} = \mathbf{P}_{\mathbf{Z}}\mathbf{X} = \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'\mathbf{X}.$$

2º Estágio: estime $\mathbf{y}$ sobre $\widehat{\mathbf{X}}$ por OLS:

$$\hat{\boldsymbol{\delta}}_{2SLS} = (\widehat{\mathbf{X}}'\widehat{\mathbf{X}})^{-1}\widehat{\mathbf{X}}'\mathbf{y}.$$

Intuição: $\widehat{\mathbf{X}}$ "limpa" os regressores endógenos, retendo apenas a variação explicada pelos instrumentos (exógena por construção).

Cuidado

Os erros-padrão do OLS no 2º estágio são *incorretos*. Os resíduos para $\hat{\sigma}^2$ devem ser os da *equação estrutural*: $\hat{\varepsilon}_i = y_i - \mathbf{x}_i'\hat{\boldsymbol{\delta}}_{2SLS}$.

Variância do MQ2E

Sob homocedasticidade condicional, a variância assintótica simplifica para:

$$\operatorname{Avar}(\hat{\boldsymbol{\delta}}_{2SLS}) = \sigma^2 \left(\boldsymbol{\Sigma}_{\mathbf{zx}}' \boldsymbol{\Sigma}_{\mathbf{zz}}^{-1} \boldsymbol{\Sigma}_{\mathbf{zx}}\right)^{-1}.$$

Estimador consistente:

$$\widehat{\operatorname{Avar}}(\hat{\boldsymbol{\delta}}_{2SLS}) = \hat{\sigma}^2 \left(\mathbf{X}'\mathbf{P}_{\mathbf{Z}}\mathbf{X}\right)^{-1}, \qquad \hat{\sigma}^2 = \frac{1}{n}\hat{\boldsymbol{\varepsilon}}'\hat{\boldsymbol{\varepsilon}} = \frac{1}{n}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\delta}}_{2SLS})'(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\delta}}_{2SLS}).$$

GMM sem Homocedasticidade

Quando $\mathrm{E}(\varepsilon_i^2 \mid \mathbf{z}_i) \neq \sigma^2$, o 2SLS **não** é eficiente. O GMM eficiente usa $\widehat{\mathbf{W}} = \widehat{\mathbf{S}}^{-1}$ com

$$\widehat{\mathbf{S}} = \frac{1}{n}\mathbf{Z}'\hat{\mathbf{\Omega}}\mathbf{Z}, \qquad \hat{\mathbf{\Omega}} = \mathrm{diag}(\hat{\varepsilon}_1^2, \ldots, \hat{\varepsilon}_n^2).$$

Procedimento em 2 passos:

1. Estime por 2SLS. Calcule resíduos $\hat{\varepsilon}^{(1)}$ e construa $\widehat{\mathbf{S}}^{(1)} = \frac{1}{n}\mathbf{Z}'\hat{\mathbf{\Omega}}^{(1)}\mathbf{Z}$.
2. Reestime com $\widehat{\mathbf{W}} = (\widehat{\mathbf{S}}^{(1)})^{-1}$:

$$\hat{\boldsymbol{\delta}}_{GMM} = \left(\mathbf{S}_{\mathbf{zx}}'(\widehat{\mathbf{S}}^{(1)})^{-1}\mathbf{S}_{\mathbf{zx}}\right)^{-1}\mathbf{S}_{\mathbf{zx}}'(\widehat{\mathbf{S}}^{(1)})^{-1}\mathbf{s}_{\mathbf{z}y}.$$

Variância estimada: $\widehat{\mathrm{Avar}} = \left(\mathbf{S}_{\mathbf{zx}}'\widehat{\mathbf{S}}^{-1}\mathbf{S}_{\mathbf{zx}}\right)^{-1}$.

Teste de Sargan (caso homocedasticidade)

Sob homocedasticidade, o teste de Hansen (Aula 1) assume a forma do **teste de Sargan**, que tem uma interpretação intuitiva:

$$\text{Sargan} = \frac{\hat{\varepsilon}' \mathbf{P}_{\mathbf{Z}} \hat{\varepsilon}}{\hat{\sigma}^2} = n \cdot R^2_{aux},$$

onde R^2_{aux} é o R^2 da regressão auxiliar dos resíduos 2SLS sobre os instrumentos $\mathbf{Z}$.

Sob H_0: "todos os K instrumentos são válidos":

$$\text{Sargan} \xrightarrow{d} \chi^2(K - L).$$

Quando há heterocedasticidade, o Sargan **não** é válido. Use o teste de Hansen com $\widehat{\mathbf{S}} = \frac{1}{n}\mathbf{Z}'\hat{\mathbf{\Omega}}\mathbf{Z}$.

Resumo: Relação entre os Estimadores

Estimador	K vs L	Premissa extra	$\widehat{\mathbf{W}}$
IV	$K = L$	—	qualquer
MQ2E (2SLS)	$K \geq L$	homocedasticidade	$\mathbf{S}_{\mathbf{zz}}^{-1} = \frac{n}{\mathbf{Z}'\mathbf{Z}}$
GMM eficiente	$K \geq L$	—	$\widehat{\mathbf{S}}^{-1}$

- MQ2E = IV quando $K = L$.
- GMM eficiente = MQ2E sob homocedasticidade.
- GMM eficiente domina MQ2E (em variância assintótica) sob heterocedasticidade.