GMM – Parte III

Aplicações

Claudio Lucinda

FEA/USP

Overview

1. GMM e Máxima Verossimilhança
2. Escolha Discreta com Dados Agregados
3. Estimação de Funções de Produção
4. Painéis Dinâmicos como GMM

MLE como Caso Especial do GMM

Seja $f(y_i \mid \mathbf{x}_i, \boldsymbol{\beta})$ a densidade verdadeira de y_i. O MLE maximiza a log-verossimilhança $(1/n)\sum_i \log f(y_i \mid \mathbf{x}_i, \boldsymbol{\beta})$, o que equivale a resolver as **equações de score**:

$$\mathbf{g}_n(\hat{\boldsymbol{\beta}}_{ML}) = \frac{1}{n}\mathbf{D}'\boldsymbol{\iota}_n \;\equiv\; \frac{1}{n}\sum_{i=1}^{n} \underbrace{\frac{\partial \log f(y_i \mid \mathbf{x}_i, \hat{\boldsymbol{\beta}}_{ML})}{\partial \boldsymbol{\beta}}}_{\mathbf{d}_i(\boldsymbol{\beta})} = \mathbf{0},$$

onde $\mathbf{D}$ é a matriz $n \times p$ de scores individuais.

A condição de momento populacional $\mathrm{E}[\mathbf{d}_i(\boldsymbol{\beta}_0)] = \mathbf{0}$ (equação de informação de Fisher) garante consistência.

Como há p condições para p parâmetros ($K = L$), o MLE é um estimador de MM *exatamente identificado* — o critério $J_{\min} = 0$ e não há teste de sobre-identificação.

Variância do MLE via GMM

Da Aula 1, a variância assintótica do GMM com $K = L$ e qualquer $\mathbf{W}$ é:

$$\operatorname{Avar}(\hat{\boldsymbol{\beta}}_{ML}) = \boldsymbol{\Sigma}_{\mathbf{D}}^{-1}\, \mathbf{S}\, (\boldsymbol{\Sigma}_{\mathbf{D}}')^{-1},$$

onde:

- $\boldsymbol{\Sigma}_{\mathbf{D}} = \mathrm{E}\left[\dfrac{\partial \mathbf{d}_i(\boldsymbol{\beta}_0)}{\partial \boldsymbol{\beta}'}\right] = \mathrm{E}[\mathbf{H}_i(\boldsymbol{\beta}_0)]$ (Hessiano esperado).
- $\mathbf{S} = \mathrm{E}[\mathbf{d}_i \mathbf{d}_i']$ (variância do score).

Pela **Equação de Informação de Fisher**: $\mathbf{S} = -\boldsymbol{\Sigma}_{\mathbf{D}} = \mathcal{I}(\boldsymbol{\beta}_0)$.
Substituindo: $\operatorname{Avar}(\hat{\boldsymbol{\beta}}_{ML}) = \mathcal{I}(\boldsymbol{\beta}_0)^{-1}$ — o resultado clássico.

Motivação: Demanda com Dados de Mercado

- Em muitas aplicações de IO não temos microdados de escolha individual, mas apenas **dados agregados de mercado**: quantidades vendidas, preços e características dos produtos.
- Supondo que consumidores escolham de acordo com um modelo de utilidade aleatória, a quantidade vendida do produto j no mercado de tamanho M é:

$$q_j = M \times s_j(\boldsymbol{\delta}, \boldsymbol{\xi}),$$

  onde s_j é a participação de mercado prevista pelo modelo, $\boldsymbol{\delta}$ são parâmetros e $\boldsymbol{\xi}_j$ são atributos do produto não observados pelo econometrista ("qualidade inobservável").
- O problema central: $\boldsymbol{\xi}_j$ é correlacionado com o preço p_j (firmas cobram mais por produtos percebidos como melhores) $\Rightarrow$ **endogeneidade de preço**.

O Bem Externo e o Tamanho do Mercado

- Inclui-se um **bem externo** ("não comprar", bem $j = 0$) para que um aumento generalizado de preços possa reduzir a demanda total. Sem ele, as participações somam 1 e só diferenças de preços importam.
- O bem externo exige que se estime o tamanho do mercado M:

$$s_0 = 1 - \sum_{j=1}^{J} s_j, \qquad q_0 = M \times s_0.$$

- Sob o modelo Logit Multinomial, a utilidade do consumidor i pelo produto j é $u_{ij} = V_j + \xi_j + \eta_{ij}$, com $\eta_{ij} \sim$ Tipo-I Valor Extremo.

Especificação Logit – Berry (1994)

Com η_{ij} i.i.d. Tipo-I VE, as participações de mercado são:

$$s_j = \frac{e^{V_j+\xi_j}}{1+\sum_{k=1}^{J} e^{V_k+\xi_k}}, \qquad s_0 = \frac{1}{1+\sum_{k=1}^{J} e^{V_k+\xi_k}}.$$

Tomando $\ln s_j - \ln s_0$ (Berry 1994), obtemos a especificação linear:

$$\ln s_j - \ln s_0 = V_j + \xi_j.$$

Com $V_j = \mathbf{x}_j'\boldsymbol{\beta} - \alpha p_j$ (utilidade média linear em características $\mathbf{x}_j$ e preço p_j):

$$\underbrace{\ln s_j - \ln s_0}_{y_j} = \mathbf{x}_j'\boldsymbol{\beta} - \alpha p_j + \xi_j.$$

Esta equação pode ser estimada por **GMM/IV** usando instrumentos para p_j.

Especificação Nested Logit

O Logit impõe IIA (*Independence of Irrelevant Alternatives*), uma hipótese restritiva. Uma extensão é o **Nested Logit** (Berry 1994):

$$\ln s_j - \ln s_0 = \mathbf{x}_j'\boldsymbol{\beta} - \alpha p_j + (1-\sigma)\ln s_{j|g} + \xi_j,$$

onde:

- g: grupo ("ninho") ao qual o produto j pertence (definido pelo analista).
- $s_{j|g}$: participação de j *dentro do grupo* g.
- $\sigma \in [0,1)$: parâmetro de correlação intragrupo. Com $\sigma = 0$ colapsa para o Logit simples.

Atenção: $s_{j|g}$ é endógeno (correlacionado com ξ_j) $\Rightarrow$ precisa de instrumento adicional.

Instrumentos para Modelos de Demanda

Por que p_j é endógeno? A firma conhece ξ_j ao fixar preço; produtos com ξ_j alto terão preços mais altos.

Instrumentos de BLP (Berry, Levinsohn e Pakes 1995):

- Características dos *outros* produtos da mesma firma (medem poder de mercado via substituição interna).
- Características dos produtos das *firmas rivais* (medem competição externa).
- Custos de produção ou preços de insumos (quando disponíveis).

Instrumentos de "Diferenciação" (Gandhi & Houde 2020): distâncias no espaço de características entre produtos concorrentes.

A condição de validade: características dos concorrentes afetam preço (via equilíbrio) mas não afetam ξ_j diretamente.

O Problema: Endogeneidade na Função de Produção

Considere a função de produção log-linear:

$$q_{it} = \beta_0 + \beta_k k_{it} + \beta_l l_{it} + \omega_{it} + \eta_{it},$$

onde ω_{it} é produtividade observada pela firma (mas não pelo econometrista) e η_{it} é um choque não observado por nenhum dos dois.

Problema de Marschak-Andrews (1944): a firma escolhe l_{it} (insumo variável) *após observar* ω_{it}, tornando l_{it} correlacionado com ω_{it}.

Direção do viés:

- Firms mais produtivas (ω_{it} alto) *contratam mais* $\Rightarrow$ OLS tende a *sobrestimar* β_l.
- Porém, em cross-section, firmas mais produtivas podem precisar de *menos* trabalho para a mesma produção $\Rightarrow$ pode ir para qualquer lado.

Problema Adicional: Atrito da Amostra

- Taxas de saída do mercado são elevadas (Dunne, Roberts e Samuelson 1988: $> 30\%$ em intervalos de 5 anos).
- A decisão de saída depende da produtividade ω_{it}:

$$\text{firma sai se } \Pi(\omega_{it}, k_{it}, \ldots) < \Psi \quad (\Psi = \text{valor de liquidação}).$$

- Firmas com mais capital suportam choques piores antes de sair $\Rightarrow \omega_{it}$ e k_{it} ficam correlacionados *condicional a estar na amostra*.
- Consequência: OLS (e mesmo IV simples) produz estimativas viesadas mesmo para β_k.

Solução I: Dados em Painel

Se $\omega_{it} = \omega_i$ (efeito fixo constante), podemos eliminar a endogeneidade por within-transformation:

$$\text{Primeiras Diferenças: } \Delta q_{it} = \beta_k \Delta k_{it} + \beta_l \Delta l_{it} + \Delta \eta_{it}.$$

Vantagens: elimina toda heterogeneidade não observada constante.

Limitações:

- A hipótese $\omega_{it} = \omega_i$ é implausível em painéis longos.
- Quando há erros de medida, a transformação amplifica o ruído relativo ao sinal, piorando as estimativas de β_k (Griliches e Hausman 1986).
- Estimativas de retornos de escala tendem a ser muito baixas.
- Resultados diferem muito entre painel balanceado e completo.

Solução II: Variáveis Instrumentais Tradicionais

Instrumentos candidatos para l_{it} e k_{it}:

- Preços de insumos (salários, preço do capital).
- Premissa: preços de insumos afetam quantidades mas são independentes de ω_{it} (sem poder de mercado no mercado de insumos).

Problemas práticos:

- Preços de insumos frequentemente não são reportados nas bases de dados.
- Pouca variação cross-sectional em preços de insumos (especialmente em dados por setor).
- É difícil defender que ω_{it} seja independente dos preços de insumos (firmas mais produtivas podem pagar salários maiores).
- IV simples não resolve o problema de atrito da amostra.

Modelo de Painel Dinâmico

Permitindo que ω_{it} seja dinâmico (AR(1)) e separando o efeito fixo:

$$q_{it} = \gamma_t + \beta_k k_{it} + \beta_l l_{it} + f_i + \eta_{it}, \qquad \eta_{it} = \rho \eta_{it-1} + \varepsilon_{it}, \quad \varepsilon_{it} \sim \text{MA}(0).$$

Após substituição do processo AR(1), obtemos a forma reduzida dinâmica:

$$q_{it} = \pi_1 l_{it} + \pi_2 l_{it-1} + \pi_3 k_{it} + \pi_4 k_{it-1} + \pi_5 q_{it-1} + \gamma_t^* + (f_i^* + \varepsilon_{it}),$$

sujeita a **restrições de sobre-identificação**: $\pi_2 = -\pi_1 \pi_5$ e $\pi_4 = -\pi_3 \pi_5$.
Estimá-la sem restrições e depois testar as restrições é um teste da especificação AR(1).

GMM-Diff: Arellano e Bond (1991)

Problema: f_i^* é correlacionado com os regressores. **Solução:** tomar primeiras diferenças para eliminar f_i^*:

$$\Delta q_{it} = \pi_1 \Delta l_{it} + \pi_2 \Delta l_{it-1} + \pi_3 \Delta k_{it} + \pi_4 \Delta k_{it-1} + \pi_5 \Delta q_{it-1} + \Delta \varepsilon_{it}.$$

Condições de momento: sob exogeneidade sequencial dos níveis defasados,

$$\mathrm{E}(\mathbf{x}_{it-s}\, \Delta \varepsilon_{it}) = \mathbf{0}, \qquad s \geq 2,$$

onde $\mathbf{x}_{it} = (q_{it}, l_{it}, k_{it})'$. Estas são as condições de momento do **GMM-Diff**.

Problema do GMM-Diff: quando os níveis $\mathbf{x}_{it-s}$ são muito persistentes (próximos de raiz unitária), eles são instrumentos **fracos** para as primeiras diferenças $\Delta \mathbf{x}_{it}$.

GMM-System: Blundell e Bond (1998)

Ideia: adicionar equações em *níveis* ao sistema, usando *primeiras diferenças* como instrumentos para os níveis.

Condição adicional ("condição de estacionaridade inicial"):

$$\mathrm{E}(\Delta \mathbf{x}_{it-1}\, f_i^*) = \mathbf{0}.$$

Condições de momento adicionais para a equação em níveis:

$$\mathrm{E}(\Delta \mathbf{x}_{it-1}\, (f_i^* + \varepsilon_{it})) = \mathbf{0}, \qquad s = 1.$$

O estimador **GMM-System** empilha as duas equações (diferenças + níveis) e usa o conjunto combinado de condições de momento.

Vantagens: ganho substancial de eficiência quando os processos são persistentes; estimativas de β_k mais razoáveis.

Testes de Validade no Painel Dinâmico

(1) Teste de Hansen (J-test): testa a validade de *todas* as condições de momento. Rejeição indica instrumentos inválidos ou especificação incorreta do processo de η.

(2) Diferença de Sargan (C-test): testa a validade das condições de momento *adicionais* do GMM-System (as condições de diferença) relativamente ao GMM-Diff:

$$C = J_{\text{system}} - J_{\text{diff}} \xrightarrow{d} \chi^2(K_{\text{sys}} - K_{\text{diff}}).$$

Se C for rejeitado, a condição de estacionaridade inicial é questionável.

(3) Teste de autocorrelação de Arellano-Bond: testa se $\Delta\varepsilon_{it}$ tem autocorrelação de 2ª ordem (o que invalidaria $\mathbf{x}_{it-2}$ como instrumento):

- AR(1) em $\Delta\varepsilon$ é esperado mesmo sob H_0 (artefato da diferença).
- AR(2) em $\Delta\varepsilon$ *não* deve existir sob H_0.

Limitações do GMM-Diff e Perspectivas

- GMM-Diff frequentemente produz estimativas muito baixas de β_l e β_k com grandes erros-padrão — sinal de instrumentos fracos.
- A transformação em diferenças amplifica erros de medida nos insumos (mesmo problema que efeitos fixos em painel simples).
- O GMM-System mitiga o problema de instrumentos fracos, mas requer a hipótese adicional de estacionaridade inicial.
- **Abordagens alternativas** (além do escopo desta aula):
  - Olley e Pakes (1996): usa investimento como proxy para ω_{it}.
  - Levinsohn e Petrin (2003): usa insumos intermediários como proxy.
  - Ackerberg, Caves e Frazer (2015): corrige problemas de colinearidade nos métodos de proxy.