

Modelos de Escolha Discreta

Bibliografia: Greene, cap. 21

Claudio Lucinda

FEA/USP



Overview

- 1 Discrete Choice
- 2 Efeitos Marginais
- 3 Index Models e Variáveis Latentes
- 4 Estimação e Inferência em Modelos de Escolha Discreta
 - Efeitos Marginais e Elasticidades
- 5 Modelos de Escolha Discreta Multivariados



Discrete Choice

- Os modelos para explicar uma variável dependente binária (0/1) normalmente surgem em dois contextos.
- Com dados sobre a variável de interesse e um conjunto de covariadas, o analista está interessado em especificar uma relação entre a primeira (discreta) e a última (contínua).
- Em outros casos, o modelo de escolha binária surge no contexto de um modelo no qual a natureza dos dados observados dita o tratamento especial de um modelo de escolha binária.
- Por exemplo, num modelo de procura de bilhetes para eventos desportivos, em que a variável de interesse seja o número de bilhetes, pode acontecer que a observação consista apenas em saber se o recinto desportivo está lotado (demanda superior ou igual a capacidade então $Y = 1$) ou não ($Y = 0$).
- Geralmente, os modelos e técnicas usados em ambos os casos são os mesmos. No entanto, é útil examinar ambos.



Discrete Choice

- O entrevistado trabalha ou procura trabalho ($Y = 1$) ou não ($Y = 0$) no período em que nossa pesquisa é realizada.
- Acreditamos que um conjunto de fatores, como idade, estado civil, escolaridade e histórico profissional, reunidos em um vetor \mathbf{x} explicam a decisão, de modo que

$$\text{Prob}(Y = 1 \mid \mathbf{x}) = F(\mathbf{x}, \beta) \quad (1)$$

$$\text{Prob}(Y = 0 \mid \mathbf{x}) = 1 - F(\mathbf{x}, \beta). \quad (2)$$

O conjunto de parâmetros β reflete o impacto das mudanças em \mathbf{x} na probabilidade. Por exemplo, entre os fatores que podem nos interessar está o efeito marginal do estado civil na probabilidade de participação na força de trabalho. O problema neste ponto é criar um modelo adequado para o lado direito da equação.



Linear Probability Models

Uma possibilidade é manter a conhecida regressão linear,

$$F(\mathbf{x}, \beta) = \mathbf{x}'\beta$$

Como $E[y | \mathbf{x}] = F(\mathbf{x}, \beta)$, podemos construir o modelo de regressão,

$$y = E[y | \mathbf{x}] + (y - E[y | \mathbf{x}]) = \mathbf{x}'\beta + \varepsilon$$

O modelo de probabilidade linear tem uma série de deficiências. Uma pequena complicação surge porque ε é heterocedástico de uma forma que depende de β . Como $\mathbf{x}'\beta + \varepsilon$ deve ser igual a 0 ou 1, ε é igual a $-\mathbf{x}'\beta$ ou $1 - \mathbf{x}'\beta$, com probabilidades $1 - F$ e F , respectivamente. Assim, você pode facilmente mostrar que

$$\text{Var}[\varepsilon | \mathbf{x}] = \mathbf{x}'\beta (1 - \mathbf{x}'\beta)$$

Uma falha mais séria é que, sem algum ajuste ad hoc com o termo erro, não podemos ter certeza de que as previsões desse modelo realmente parecerão probabilidades.



Modelos de Escolha Discreta e link functions

Nosso requisito, então, é um modelo que produzirá previsões consistentes com a teoria subjacente em (21-1). Para um determinado vetor de regressores, esperaríamos

$$\lim_{\mathbf{x}'\beta \rightarrow +\infty} \text{Prob}(Y = 1 \mid \mathbf{x}) = 1$$

$$\lim_{\mathbf{x}'\beta \rightarrow -\infty} \text{Prob}(Y = 1 \mid \mathbf{x}) = 0.$$

A princípio, qualquer distribuição de probabilidade contínua adequada definida sobre a linha real será suficiente. A distribuição normal tem sido utilizada em muitas análises, dando origem ao modelo probit,

$$\text{Prob}(Y = 1 \mid \mathbf{x}) = \int_{-\infty}^{\mathbf{x}'\beta} \phi(t) dt = \Phi(\mathbf{x}'\beta).$$

A função $\Phi(\cdot)$ é uma notação comumente usada para a distribuição normal padrão.



Modelos de Escolha Discreta

Em parte devido à sua conveniência matemática, a distribuição logística,

$$\text{Prob}(Y = 1 \mid \mathbf{x}) = \frac{e^{\mathbf{x}'\beta}}{1 + e^{\mathbf{x}'\beta}} = \Lambda(\mathbf{x}'\beta)$$

também tem sido usado em muitas aplicações. Usaremos a notação $\Lambda(\cdot)$ para indicar a função de distribuição cumulativa logística, também é chamado de modelo logit por motivos que discutiremos na próxima seção. Ambas as distribuições têm a conhecida forma de sino das distribuições simétricas. Outros modelos que não assumem simetria, como o modelo Weibull

$$\text{Prob}(Y = 1 \mid \mathbf{x}) = \exp[-\exp(\mathbf{x}'\beta)]$$

e modelo log log complementar (CLOGLOG),

$$\text{Prob}(Y = 1 \mid \mathbf{x}) = 1 - \exp[\exp(-\mathbf{x}'\beta)]$$

Mas o Probit e o Logit são os mais comumente utilizados



Efeitos Marginais

O modelo de probabilidade é uma regressão:

$$E[y \mid \mathbf{x}] = 0 [1 - F(\mathbf{x}'\boldsymbol{\beta})] + 1 [F(\mathbf{x}'\boldsymbol{\beta})] = F(\mathbf{x}'\boldsymbol{\beta}).$$

Qualquer que seja a distribuição utilizada, é importante observar que os parâmetros do modelo, como os de qualquer modelo de regressão não linear, não são necessariamente os efeitos marginais que estamos acostumados a analisar. Em geral,

$$\frac{\partial E[y \mid \mathbf{x}]}{\partial \mathbf{x}} = \left\{ \frac{dF(\mathbf{x}'\boldsymbol{\beta})}{d(\mathbf{x}'\boldsymbol{\beta})} \right\} \boldsymbol{\beta} = f(\mathbf{x}'\boldsymbol{\beta}) \boldsymbol{\beta},$$



Efeitos Marginais – Probit e Logit

Para a distribuição normal, esse resultado é

$$\frac{\partial E[y \mid \mathbf{x}]}{\partial \mathbf{x}} = \phi(\mathbf{x}'\boldsymbol{\beta}) \boldsymbol{\beta}$$

onde $\phi(t)$ é a densidade normal padrão. Para a distribuição logística,

$$\frac{d\Lambda(\mathbf{x}'\boldsymbol{\beta})}{d(\mathbf{x}'\boldsymbol{\beta})} = \frac{e^{\mathbf{x}'\boldsymbol{\beta}}}{(1 + e^{\mathbf{x}'\boldsymbol{\beta}})^2} = \Lambda(\mathbf{x}'\boldsymbol{\beta}) [1 - \Lambda(\mathbf{x}'\boldsymbol{\beta})]$$

Assim, no modelo logit,

$$\frac{\partial E[y \mid \mathbf{x}]}{\partial \mathbf{x}} = \Lambda(\mathbf{x}'\boldsymbol{\beta}) [1 - \Lambda(\mathbf{x}'\boldsymbol{\beta})] \boldsymbol{\beta}$$



Efeitos Marginais

- Para calcular os efeitos marginais, pode-se avaliar as expressões nas médias amostrais dos dados ou avaliar os efeitos marginais em cada observação e usar a média amostral dos efeitos marginais individuais.
- As funções são contínuas com primeiras derivadas contínuas, então o Teorema D.12 (o teorema de Slutsky) e assumindo que os dados são "bem comportados" uma lei de grandes números (Teoremas D.4 e D.5) se aplica;
- Em grandes amostras, eles darão a mesma resposta. Mas isso não ocorre em amostras pequenas ou moderadas.
- A prática atual favorece a média dos efeitos marginais individuais quando é possível fazê-lo.
- Efeito Marginal de uma dummy:

$$\text{Ef. marginal} = \text{Prob} [Y = 1 \mid \bar{\mathbf{x}}_{(d)}, d = 1] - \text{Prob} [Y = 1 \mid \bar{\mathbf{x}}_{(d)}, d = 0]$$



Index Models e Variáveis Latentes

- Vemos o resultado de uma escolha discreta como um reflexo de uma regressão subjacente.
- Como um exemplo frequentemente citado, considere a decisão de fazer uma grande compra.
- A teoria afirma que o consumidor faz um cálculo de custo-benefício na margem com base nas utilidades obtidas ao fazer a compra e ao não fazer a compra e ao usar o dinheiro para outra coisa.
- Modelamos a diferença entre benefício e custo como uma variável não observada y^* tal que

$$y^* = \mathbf{x}'\boldsymbol{\beta} + \varepsilon$$



Index Models e Variáveis Latentes

- Assumimos que ε tem média zero e possui uma logística padronizada com variância (conhecida) $\pi^2/3$ ou uma distribuição normal padrão com variância um.
- Não observamos o benefício líquido da compra, apenas se ela é feita ou não.
- Portanto, nossa observação é:

$$\begin{aligned} y &= 1 && \text{se } y^* > 0, \\ y &= 0 && \text{se } y^* \leq 0. \end{aligned}$$

Nessa formulação, $\mathbf{x}'\boldsymbol{\beta}$ é chamada de index function.



Index Models e Variáveis Latentes- Identificação

- Primeiro, a suposição de variância conhecida de ε é uma normalização inocente.
- Suponha que a variância de ε seja escalada por um parâmetro irrestrito σ^2 .
- A regressão latente será $y^* = \mathbf{x}'\boldsymbol{\beta} + \sigma\varepsilon$.
- Mas, $(y^*/\sigma) = \mathbf{x}'(\boldsymbol{\beta}/\sigma) + \varepsilon$ é o mesmo modelo com os mesmos dados.
- Isso significa que σ não pode ser numericamente identificado pelos dados.



Identificação - II

- Em segundo lugar, a suposição de zero para o limite também é inocente somente se o modelo contiver uma constante
- Seja a o suposto limiar diferente de zero e α seja um termo constante desconhecido e, por enquanto, \mathbf{x} e β contêm o resto do índice não incluindo o termo constante. Então, a probabilidade de que y seja igual a um é

$$\text{Prob}(y^* > a \mid \mathbf{x}) = \text{Prob}(\alpha + \mathbf{x}'\beta + \varepsilon > a \mid \mathbf{x}) = \text{Prob}[(\alpha - a) + \mathbf{x}'\beta + \varepsilon > 0 \mid \mathbf{x}]$$

Como α é desconhecido, a diferença $(\alpha - a)$ permanece um parâmetro desconhecido. Com as duas normalizações,

$$\text{Prob}(y^* > 0 \mid \mathbf{x}) = \text{Prob}(\varepsilon > -\mathbf{x}'\beta \mid \mathbf{x}).$$



Estimação e Inferência em Modelos de Escolha Discreta

- Com exceção do modelo de probabilidade linear, a estimativa de modelos de escolha binária geralmente é baseada no método de máxima verossimilhança.
- Cada observação é tratada como um único sorteio de uma distribuição de Bernoulli (binomial com um sorteio).
- O modelo com probabilidade de sucesso $F(\mathbf{x}'\beta)$ e observações independentes leva à probabilidade conjunta, ou função de verossimilhança,

$$\text{Prob}(Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n \mid \mathbf{X}) = \prod_{y_i=0} [1 - F(\mathbf{x}'_i\beta)] \prod_{y_i=1} F(\mathbf{x}'_i\beta)$$

Em que \mathbf{X} representa $[\mathbf{x}_i]_{i=1, \dots, n}$. A log verossimilhança é

$$\ln L = \sum_{i=1}^n \{y_i \ln F(\mathbf{x}'_i\beta) + (1 - y_i) \ln [1 - F(\mathbf{x}'_i\beta)]\}$$



Scores da ML

As derivadas da função verossimilhança são:

$$\frac{\partial \ln L}{\partial \beta} = \sum_{i=1}^n \left[\frac{y_i f_i}{F_i} + (1 - y_i) \frac{-f_i}{(1 - F_i)} \right] \mathbf{x}_i = \mathbf{0}$$

Em que f_i é a densidade, $dF_i/d(\mathbf{x}_i'\beta)$. Para o logit, isso fica:

$$\frac{\partial \ln L}{\partial \beta} = \sum_{i=1}^n (y_i - \Lambda_i) \mathbf{x}_i = \mathbf{0}.$$

Observe que se \mathbf{x}_i contém um termo constante, as condições de primeira ordem implicam que a média das probabilidades previstas deve ser igual à proporção de uns na amostra. Essa implicação também tem alguma semelhança com as equações normais de mínimos quadrados se considerarmos o termo $y_i - \Lambda_i$ como um resíduo.



Scores da ML II

$$\ln L = \sum_{y_i=0} \ln [1 - \Phi(\mathbf{x}'_i \boldsymbol{\beta})] + \sum_{y_i=1} \ln \Phi(\mathbf{x}'_i \boldsymbol{\beta})$$

Os scores de L são

$$\frac{\partial \ln L}{\partial \boldsymbol{\beta}} = \sum_{y_i=0} \frac{-\phi_i}{1 - \Phi_i} \mathbf{x}_i + \sum_{y_i=1} \frac{\phi_i}{\Phi_i} \mathbf{x}_i = \sum_{y_i=0} \lambda_i^0 \mathbf{x}_i + \sum_{y_i=1} \lambda_i^1 \mathbf{x}_i.$$

Ou – derivação para o leitor interessado:

$$\frac{\partial \log L}{\partial \boldsymbol{\beta}} = \sum_{i=1}^n \left[\frac{q_i \phi(q_i \mathbf{x}'_i \boldsymbol{\beta})}{\Phi(q_i \mathbf{x}'_i \boldsymbol{\beta})} \right] \mathbf{x}_i = \sum_{i=1}^n \lambda_i \mathbf{x}_i = \mathbf{0}.$$

where $q_i = 2y_i - 1$



Hessianos

Logit:

The actual second derivatives for the logit model are quite simple:

$$\mathbf{H} = \frac{\partial^2 \ln L}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}'} = - \sum_i \Lambda_i (1 - \Lambda_i) \mathbf{x}_i \mathbf{x}_i'$$

Para o probit

$$\mathbf{H} = \frac{\partial^2 \ln L}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}'} = \sum_{i=1}^n -\lambda_i (\lambda_i + \mathbf{x}_i' \boldsymbol{\beta}) \mathbf{x}_i \mathbf{x}_i'$$

Efeitos Marginais e Elasticidades

- As probabilidades previstas, $F(\mathbf{x}'\hat{\beta}) = \hat{F}$ e os efeitos marginais estimados $f(\mathbf{x}'\hat{\beta}) \times \hat{\beta} = \hat{f}\hat{\beta}$ são funções não lineares das estimativas dos parâmetros.
- Para calcular os erros padrão, podemos usar a abordagem de aproximação linear (método delta). Para as probabilidades previstas,

$$\text{Asy. Var}[\hat{F}] = [\partial \hat{F} / \partial \hat{\beta}]' \mathbf{V} [\partial \hat{F} / \partial \hat{\beta}]$$

em que

$$\mathbf{V} = \text{Asy. Var}[\hat{\beta}]$$



Efeitos Marginais e Elasticidades II

A matriz de covariância assintótica estimada de $\hat{\beta}$ pode ser qualquer uma das descritas anteriormente. Seja $z = \mathbf{x}'\hat{\beta}$. Então o vetor de derivadas é

$$[\partial \hat{F} / \partial \hat{\beta}] = [d\hat{F} / dz][\partial z / \partial \hat{\beta}] = \hat{f} \mathbf{x}$$

Reorganizando, temos

$$\text{Asy. Var}[\hat{F}] = \hat{f}^2 \mathbf{x}' \mathbf{V} \mathbf{x}$$

No caso de um x binário, isso fica

$$\text{Asy. Var}[\Delta \hat{F}] = [\partial \Delta \hat{F} / \partial \hat{\beta}]' \mathbf{V} [\partial \Delta \hat{F} / \partial \hat{\beta}]$$

em que

$$[\partial \Delta \hat{F} / \partial \hat{\beta}] = \hat{f}_1 \begin{pmatrix} \bar{\mathbf{x}}_{(d)} \\ 1 \end{pmatrix} - \hat{f}_0 \begin{pmatrix} \bar{\mathbf{x}}_{(d)} \\ 0 \end{pmatrix}.$$



Efeitos Marginais - Probit e Logit

No modelo Probit, $df/dz = -z\phi$, então

$$\text{Asy. Var}[\hat{\gamma}] = \phi^2 [\mathbf{I} - (\beta' \mathbf{x}) \beta \mathbf{x}'] \mathbf{V} [\mathbf{I} - (\beta' \mathbf{x}) \beta \mathbf{x}']'.$$

Para o Logit, $\hat{f} = \hat{\Lambda}(1 - \hat{\Lambda})$, então

$$\frac{d\hat{f}}{dz} = (1 - 2\hat{\Lambda}) \left(\frac{d\hat{\Lambda}}{dz} \right) = (1 - 2\hat{\Lambda})\hat{\Lambda}(1 - \hat{\Lambda}).$$

Reorganizando, obtemos

$$\text{Asy. Var}[\hat{\gamma}] = [\Lambda(1 - \Lambda)]^2 [\mathbf{I} + (1 - 2\Lambda)\beta \mathbf{x}'] \mathbf{V} [\mathbf{I} + (1 - 2\Lambda)\mathbf{x}\beta'].$$



Modelos de Escolha Discreta Multivariados

Uma extensão natural do modelo probit seria permitir mais de uma equação, com perturbações correlacionadas, no mesmo espírito do modelo de regressão aparentemente não relacionado. A especificação geral para um modelo de duas equações seria:

$$y_1^* = \mathbf{x}_1' \boldsymbol{\beta}_1 + \varepsilon_1, \quad y_1 = 1 \quad \text{if } y_1^* > 0, 0 \text{ otherwise,}$$

$$y_2^* = \mathbf{x}_2' \boldsymbol{\beta}_2 + \varepsilon_2, \quad y_2 = 1 \quad \text{if } y_2^* > 0, 0 \text{ otherwise,}$$

$$E[\varepsilon_1 \mid \mathbf{x}_1, \mathbf{x}_2] = E[\varepsilon_2 \mid \mathbf{x}_1, \mathbf{x}_2] = 0,$$

$$\text{Var}[\varepsilon_1 \mid \mathbf{x}_1, \mathbf{x}_2] = \text{Var}[\varepsilon_2 \mid \mathbf{x}_1, \mathbf{x}_2] = 1,$$

$$\text{Cov}[\varepsilon_1, \varepsilon_2 \mid \mathbf{x}_1, \mathbf{x}_2] = \rho.$$



MVDC - Estimação

Isso vai ser por MV A CDF Normal bivariada é

$$\text{Prob}(X_1 < x_1, X_2 < x_2) = \int_{-\infty}^{x_2} \int_{-\infty}^{x_1} \phi_2(z_1, z_2, \rho) dz_1 dz_2$$

Representada por $\Phi_2(x_1, x_2, \rho)$. A PDF é

$$\phi_2(x_1, x_2, \rho) = \frac{e^{-(1/2)(x_1^2 + x_2^2 - 2\rho x_1 x_2)/(1-\rho^2)}}{2\pi(1-\rho^2)^{1/2}}.49$$

Seja $q_{i1} = 2y_{i1} - 1$ and $q_{i2} = 2y_{i2} - 1$. Portanto, $q_{ij} = 1$ se $y_{ij} = 1$ e -1 se $y_{ij} = 0$ para $j = 1$ e 2 . Definindo

$$z_{ij} = \mathbf{x}'_{ij}\beta_j \quad \text{e} \quad w_{ij} = q_{ij}z_{ij}, \quad j = 1, 2,$$



MVDC - Estimação II

As probabilidades que entram na Log-Verossimilhança são:

$$\text{Prob}(Y_1 = y_{i1}, Y_2 = y_{i2} \mid \mathbf{x}_1, \mathbf{x}_2) = \Phi_2(w_{i1}, w_{i2}, \rho_{i*})$$

Em que

$$\rho_{i*} = q_{i1}q_{i2}\rho$$

A Log-Verossimilhança fica sendo

$$\log L = \sum_{i=1}^n \ln \Phi_2(w_{i1}, w_{i2}, \rho_{i*})$$

E os Scores

$$\frac{\partial \ln L}{\partial \beta_j} = \sum_{i=1}^n \left(\frac{q_{ij} g_{ij}}{\Phi_2} \right) \mathbf{x}_{ij}, \quad j = 1, 2,$$

$$\frac{\partial \ln L}{\partial \rho} = \sum_{i=1}^n \frac{q_{i1} q_{i2} \phi_2}{\Phi_2}, \quad g_{i1} = \phi(w_{i1}) \Phi \left[\frac{w_{i2} - \rho_{i*} w_{i1}}{\sqrt{1 - \rho_{i*}^2}} \right]$$

