# Modelos de Escolha Discreta Ordenada

## Logit e Probit Ordenado — Bibliografia: Greene, cap. 18

Claudio Lucinda

FEA/USP

# Agenda

1. Motivação
2. O Modelo de Variável Latente Ordenada
3. Estimação por Máxima Verossimilhança
4. Efeitos Marginais e Interpretação
5. Aplicação Ilustrativa

# Motivação

- Em muitas aplicações econômicas, a variável dependente assume valores discretos com uma **ordenação natural**, mas sem significado cardinal.
- Exemplos:
  - Nível de escolaridade: fundamental / médio / superior / pós-graduação
  - Grau de satisfação em pesquisas (escala Likert: 1 a 5)
  - *Rating* de crédito: AAA $>$ AA $>$ A $>$ BBB $\cdots$
  - Intensidade de uso de um produto: nunca / às vezes / frequentemente
- A diferença para o multinomial é crucial: aqui a **ordem importa** e o modelo deve explorá-la.
- Tratar como variável contínua (MQO) ignora a natureza discreta. Tratar como multinomial ignora a ordem e perde eficiência.

# Diferença Conceitual

| Característica | Binário | **Ordenado** | Multinomial |
|---|---|---|---|
| Nº de categorias | 2 | $J \geq 2$ | $J \geq 2$ |
| Ordem importa? | — | **Sim** | Não |
| Variável latente única? | Sim | **Sim** | Não |
| Parâmetros de limiar? | Não | **Sim** | Não |

- O modelo ordenado é uma **generalização direta** do probit/logit binário: a variável latente é a mesma, mas agora ela é "fatia" em múltiplas categorias por limiares.

# O Modelo de Variável Latente Ordenada

- Postulamos a existência de uma variável latente contínua:

$$y_i^* = \mathbf{x}_i'\boldsymbol{\beta} + \varepsilon_i, \quad \varepsilon_i \sim F(\cdot)$$

- O que observamos é $y_i \in \{0, 1, \ldots, J\}$, com a regra de medição:

$$y_i = j \quad \Longleftrightarrow \quad \mu_{j-1} < y_i^* \leq \mu_j$$

- Os **limiares** (ou *pontos de corte*) satisfazem:

$$-\infty = \mu_{-1} < \mu_0 < \mu_1 < \cdots < \mu_{J-1} < \mu_J = +\infty$$

- Para $J = 1$ (duas categorias) recuperamos exatamente o probit/logit binário com limiar $\mu_0 = 0$.

# Probabilidades de Cada Categoria

- A probabilidade de observar a categoria $j$ é:

$$\begin{aligned}\Pr(y_i = j \mid \mathbf{x}_i) &= \Pr(\mu_{j-1} < y_i^* \leq \mu_j) \\ &= F(\mu_j - \mathbf{x}_i'\boldsymbol{\beta}) - F(\mu_{j-1} - \mathbf{x}_i'\boldsymbol{\beta})\end{aligned}$$

- Casos extremos:

$$\Pr(y_i = 0) = F(\mu_0 - \mathbf{x}_i'\boldsymbol{\beta}), \qquad \Pr(y_i = J) = 1 - F(\mu_{J-1} - \mathbf{x}_i'\boldsymbol{\beta})$$

- Note que $\sum_{j=0}^{J} \Pr(y_i = j) = 1$ por construção.
- $F(\cdot)$ é a normal padrão $\Rightarrow$ **probit ordenado**.
  $F(\cdot)$ é a logística $\Rightarrow$ **logit ordenado**.

# Identificação do Modelo

- O modelo tem dois tipos de parâmetros livres: $\boldsymbol{\beta}$ e $(\mu_0, \mu_1, \ldots, \mu_{J-1})$.
- **Problema de identificação:** escala e localização são arbitrárias — podemos somar uma constante a $y^*$ e subtraí-la de todos os $\mu_j$ sem alterar nenhuma probabilidade.
- **Normalização padrão:** fixar a distribuição de $\varepsilon$ com $E[\varepsilon] = 0$ e $\mathrm{Var}[\varepsilon] = 1$ (probit) ou $\pi^2/3$ (logit) **e** excluir a constante de $\mathbf{x}_i'\boldsymbol{\beta}$.
- Com essa normalização, $\boldsymbol{\beta}$ e $(\mu_0, \ldots, \mu_{J-1})$ são todos identificados.

# Estimação por Máxima Verossimilhança

- Defina $d_{ij} = \mathbf{1}(y_i = j)$ e $P_{ij} = F(\mu_j - \mathbf{x}_i'\boldsymbol{\beta}) - F(\mu_{j-1} - \mathbf{x}_i'\boldsymbol{\beta})$.
- A log-verossimilhança é:

$$\ln \mathcal{L}(\boldsymbol{\beta}, \boldsymbol{\mu}) = \sum_{i=1}^{n} \sum_{j=0}^{J} d_{ij} \ln P_{ij}$$

- Para simplificar a notação, escreva $F_j^i \equiv F(\mu_j - \mathbf{x}_i'\boldsymbol{\beta})$ e $f_j^i \equiv f(\mu_j - \mathbf{x}_i'\boldsymbol{\beta})$, onde $f = F'$ é a densidade associada.
- A restrição $\mu_{j-1} < \mu_j$ é imposta diretamente na otimização (p. ex. via reparametrização $\mu_j = \mu_{j-1} + e^{\delta_j}$).

# Scores da MV — $\boldsymbol{\beta}$

- Para a observação $i$ na categoria $y_i = j$, a contribuição à log-verossimilhança é $\ln P_{ij}$.
- Derivando em relação a $\boldsymbol{\beta}$:

$$\frac{\partial \ln P_{ij}}{\partial \boldsymbol{\beta}} = \frac{-f_j^i + f_{j-1}^i}{P_{ij}} \mathbf{x}_i = \frac{f_{j-1}^i - f_j^i}{P_{ij}} \mathbf{x}_i$$

- O score total em $\boldsymbol{\beta}$:

$$\frac{\partial \ln \mathcal{L}}{\partial \boldsymbol{\beta}} = \sum_{i=1}^{n} \frac{f_{y_i-1}^i - f_{y_i}^i}{P_{i,y_i}} \mathbf{x}_i$$

- Observe a estrutura: a contribuição de $i$ pondera $\mathbf{x}_i$ pela **diferença de densidade** nos dois limiares que delimitam a categoria observada, dividida pela probabilidade daquela categoria.

# Scores da MV — Limiares $\mu_k$

- Para o limiar $\mu_k$, ele aparece na probabilidade de duas categorias adjacentes: $P_{i,k}$ e $P_{i,k+1}$.
- Score de $\mu_k$:

$$\frac{\partial \ln \mathcal{L}}{\partial \mu_k} = \sum_{i=1}^{n} \left[ \frac{d_{ik}\, f_k^i}{P_{ik}} - \frac{d_{i,k+1}\, f_k^i}{P_{i,k+1}} \right]$$

- Intuição: se $y_i = k$, um aumento em $\mu_k$ **expande** a janela da categoria $k$ (contribuição positiva); mas se $y_i = k+1$, esse mesmo aumento **comprime** a janela de $k+1$ (contribuição negativa).
- Os scores de $\boldsymbol{\beta}$ e $\boldsymbol{\mu}$ se anulam na solução, sendo a Hessiana negativa semi-definida — a função é côncava e o máximo é único (sob condições de regularidade).

# Hessiana e Inferência

- A Hessiana (e, portanto, a matriz de informação de Fisher) tem uma estrutura em bloco que envolve os termos cruzados entre $\boldsymbol{\beta}$ e os limiares $\boldsymbol{\mu}$.
- Na prática, a inferência segue o padrão de MV:

$$\sqrt{n}\,(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}\big(\mathbf{0},\, \mathcal{I}(\boldsymbol{\theta}_0)^{-1}\big)$$

- onde $\boldsymbol{\theta} = (\boldsymbol{\beta}', \boldsymbol{\mu}')'$ e $\mathcal{I}$ é a matriz de informação esperada.
- Testes de hipóteses usuais: razão de verossimilhança (RV), Wald, e escore (LM) — todos assintoticamente equivalentes.
- **Probit vs. logit ordenado:** na maioria das aplicações os resultados são muito similares; o logit tem caudas mais pesadas e é ligeiramente mais robusto a erros de especificação da cauda.

# Efeitos Marginais e Interpretação

- O efeito marginal de $x_k$ sobre a probabilidade da categoria $j$ é:

$$\frac{\partial \Pr(y = j \mid \mathbf{x})}{\partial x_k} = \left[ f(\mu_{j-1} - \mathbf{x}'\boldsymbol{\beta}) - f(\mu_j - \mathbf{x}'\boldsymbol{\beta}) \right] \beta_k$$

- Casos extremos:

$$\frac{\partial \Pr(y = 0)}{\partial x_k} = -f(\mu_0 - \mathbf{x}'\boldsymbol{\beta})\,\beta_k$$
$$\frac{\partial \Pr(y = J)}{\partial x_k} = \quad f(\mu_{J-1} - \mathbf{x}'\boldsymbol{\beta})\,\beta_k$$

- **Ponto crucial:** o **sinal** do efeito sobre as categorias *intermediárias* **não está restrito** ao sinal de $\beta_k$. Ele depende da diferença das densidades nos dois limiares adjacentes.

# Efeitos Marginais — Interpretação

- Um $\beta_k > 0$ implica:
  - Aumento em $x_k \Rightarrow$ deslocamento da distribuição de $y^*$ para a direita.
  - Probabilidade da categoria mais alta ($J$) **sobe**.
  - Probabilidade da categoria mais baixa (0) **cai**.
  - Categorias intermediárias: o efeito pode ser positivo ou negativo, a depender de onde a massa está concentrada.
- Os efeitos sobre **todas** as categorias somam zero:

$$\sum_{j=0}^{J} \frac{\partial \Pr(y = j \mid \mathbf{x})}{\partial x_k} = 0$$

- Reporte AME (*Average Marginal Effect*) ou MEM (*Marginal Effect at the Mean*) — o primeiro é geralmente preferido.

# A Hipótese de Linhas Paralelas

- O modelo ordenado impõe que $\boldsymbol{\beta}$ seja o **mesmo para todos os limiares** — só os pontos de corte variam entre categorias.
- Geometricamente, as curvas de probabilidade acumulada $\Pr(y \leq j \mid x)$ são deslocamentos horizontais umas das outras ("linhas paralelas").
- **Teste de Brant** (probit) ou equivalente: estima modelos binários separados para cada limiar e testa se os $\boldsymbol{\beta}$ diferem.
- Se a hipótese é rejeitada, alternativas incluem:
  - Logit multinomial (sem ordem) — perde eficiência.
  - Modelos de linhas não-paralelas (*generalized ordered logit*).
  - Modelos de resposta ordinal baseados em utilidade heterogênea.

# Aplicação Ilustrativa— *Rating* de Crédito Soberano

- **Variável dependente:** categoria de *rating* do país (ex.: AAA=5, AA=4, A=3, BBB=2, abaixo=1) — variável ordenada natural.
- **Covariadas x**: PIB per capita (log), crescimento do PIB, dívida/PIB, inflação, saldo em conta corrente/PIB, indicador de *default* histórico.
- **Estimação:** probit ordenado por MV.
- **Interpretação:**
  - $\hat{\beta}_{\text{dívida/PIB}} < 0$: maior endividamento $\Rightarrow$ distribuição de $y^*$ desloca-se para a esquerda, reduzindo a probabilidade dos *ratings* mais altos.
  - O efeito sobre *ratings* intermediários pode ser não-monotônico.
- **Referência clássica:** Cantor & Packer (1996), *Journal of Fixed Income*.

# Exemplo Numérico Estilizado

- 3 categorias de *rating*: $j \in \{1, 2, 3\}$, com limiares estimados $\hat{\mu}_1 = -0{,}5$ e $\hat{\mu}_2 = 1{,}2$.
- Coeficiente da dívida/PIB: $\hat{\beta} = -0{,}8$.
- Para um país com índice de endividamento médio ($\mathbf{x}'\hat{\boldsymbol{\beta}} = 0$):

| Categoria | Probabilidade | EME (dívida/PIB $\uparrow$ 10 p.p.) |
|---|---|---|
| $j = 1$ (baixo) | $\Phi(-0{,}5) \approx 0{,}31$ | $+0{,}025$ |
| $j = 2$ (médio) | $\Phi(1{,}2) - \Phi(-0{,}5) \approx 0{,}57$ | $+0{,}003$ |
| $j = 3$ (alto) | $1 - \Phi(1{,}2) \approx 0{,}12$ | $-0{,}028$ |

- O efeito na categoria intermediária é pequeno e positivo — a probabilidade que "saiu" da categoria alta se distribuiu entre as categorias 1 e 2.

# Resumo

- O modelo de logit/probit ordenado é a ferramenta natural quando a variável dependente é discreta e **ordenada**.
- Baseia-se numa única variável latente com múltiplos pontos de corte — extensão direta do modelo binário.
- Estimação por MV é direta; os scores têm estrutura intuitiva de "diferença de densidade nos limiares adjacentes".
- A **hipótese de linhas paralelas** deve sempre ser testada.
- Efeitos marginais somam zero e podem ter sinais distintos nas categorias intermediárias — reporte e interprete com cuidado.
- Próximo passo: modelos multinomiais (logit/probit sem ordem) — `Aula08Mlogit`.