

# Modelos de Escolha Discreta

Bibliografia: Greene, cap. 21

Claudio Lucinda

FEA/USP



# Overview

- 1 Truncamento
- 2 Censura
  - Modelo Tobit
- 3 Seleção de Amostra



# Introdução

- Esta aula trata do truncamento e da censura e uma forma de truncamento chamada de problema de seleção de amostras
- O efeito de truncamento ocorre quando dados de amostra são extraídos de um subconjunto de uma população maior de interesse.
  - Por exemplo, estudos de renda baseados em rendas acima ou abaixo de alguma linha de pobreza podem ser de utilidade limitada para inferências sobre toda a população.
  - O truncamento é essencialmente uma característica da distribuição da qual os dados de amostra são extraídos.
- A censura é um problema mais comum em estudos recentes.
  - Para continuar o exemplo, suponha que, em vez de não serem observadas, todas as rendas abaixo da linha da pobreza sejam relatadas como se estivessem na linha da pobreza.
- A censura de um intervalo de valores da variável de interesse introduz uma distorção nos resultados estatísticos convencionais semelhante à do truncamento.
- Ao contrário do truncamento, no entanto, a censura é essencialmente um defeito nos dados de amostra. Presumivelmente, se não fossem censurados, os dados seriam uma amostra representativa da população de interesse.



# Distribuições Truncadas

Uma distribuição truncada é a parte de uma distribuição não truncada que está acima ou abaixo de algum valor especificado. Este subconjunto é uma parte da distribuição total de renda que pode variar de zero a (essencialmente) infinito.

## Theorem (Densidade de uma Variável Aleatória Truncada)

*Se uma variável aleatória contínua  $x$  tem pdf  $f(x)$  e  $a$  é uma constante, então*

$$f(x | x > a) = \frac{f(x)}{\text{Prob}(x > a)}$$

A prova decorre da definição de probabilidade condicional e equivale apenas a dimensionar a densidade de modo que ela se integre a um na faixa acima de  $a$ . Observe que a distribuição truncada é uma distribuição condicional.



# Normal Truncada

As aplicações mais recentes baseados em variáveis aleatórias contínuas usam a distribuição normal truncada. Se  $x$  tem uma distribuição normal com média  $\mu$  e desvio padrão  $\sigma$ , então

$$\text{Prob}(x > a) = 1 - \Phi\left(\frac{a - \mu}{\sigma}\right) = 1 - \Phi(\alpha),$$

onde  $\alpha = (a - \mu)/\sigma$  e  $\Phi(\cdot)$  é a cdf normal padrão. A densidade da distribuição normal truncada é então

$$f(x | x > a) = \frac{f(x)}{1 - \Phi(\alpha)} = \frac{(2\pi\sigma^2)^{-1/2} e^{-(x-\mu)^2/(2\sigma^2)}}{1 - \Phi(\alpha)} = \frac{\frac{1}{\sigma}\phi\left(\frac{x-\mu}{\sigma}\right)}{1 - \Phi(\alpha)}$$

onde  $\phi(\cdot)$  é o pdf normal padrão.



# Momentos de Distribuições Truncadas

Geralmente estamos interessados na média e na variância da variável aleatória truncada. Eles seriam obtidos pela fórmula geral:

$$E[x \mid x > a] = \int_a^{\infty} xf(x \mid x > a)dx$$

para a média e também para a variância.

- 1 Se o truncamento for de baixo, então a média da variável truncada é maior que a média da variável original. Se o truncamento for de cima, então a média da variável truncada é menor que a média da variável original. Isso é claramente visível na Figura 22.1.
- 2 O truncamento reduz a variância em comparação com a variância na distribuição não truncada.



# Momentos da Normal Truncada

## Theorem (Momentos da Normal Truncada)

Se  $x \sim N[\mu, \sigma^2]$  e  $a$  é uma constante, então

$$E[x \mid \text{truncamento}] = \mu + \sigma \lambda(\alpha),$$

$$\text{Var}[x \mid \text{truncamento}] = \sigma^2[1 - \delta(\alpha)],$$

onde  $\alpha = (a - \mu)/\sigma$ ,  $\phi(\alpha)$  é a densidade normal padrão e

$$\lambda(\alpha) = \phi(\alpha)/[1 - \Phi(\alpha)] \quad \text{se o truncamento for } x > a,$$

$$\lambda(\alpha) = -\phi(\alpha)/\Phi(\alpha) \quad \text{se o truncamento for } x < a,$$

e

$$\delta(\alpha) = \lambda(\alpha)[\lambda(\alpha) - \alpha]$$



# Razão Inversa de Mills

Um resultado importante é

$$0 < \delta(\alpha) < 1 \text{ para todos os valores de } \alpha,$$

Um resultado que usaremos em vários pontos abaixo é  $d\phi(\alpha)/d\alpha = -\alpha\phi(\alpha)$ . A função  $\lambda(\alpha)$  é chamada de razão inversa de Mills.





# O Modelo de Regressão Truncada

No modelo dos exemplos anteriores, assumimos agora que

$$\mu_i = \mathbf{x}_i' \boldsymbol{\beta}$$

é a parte determinística do modelo de regressão clássico. Então

$$y_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i$$

onde

$$\varepsilon_i \mid \mathbf{x}_i \sim N[0, \sigma^2]$$

para que

$$y_i \mid \mathbf{x}_i \sim N[\mathbf{x}_i' \boldsymbol{\beta}, \sigma^2]$$

Estamos interessados na distribuição de  $y_i$  dado que  $y_i$  é maior que o ponto de truncamento  $a$ .



## Modelo de Regressão Truncada II

A média condicional (aos  $x$  e à truncagem) é dada por

$$E[y_i | y_i > a] = \mathbf{x}'_i \boldsymbol{\beta} + \sigma \frac{\phi[(a - \mathbf{x}'_i \boldsymbol{\beta}) / \sigma]}{1 - \Phi[(a - \mathbf{x}'_i \boldsymbol{\beta}) / \sigma]}.$$

A média condicional é, portanto, uma função não linear de  $a$ ,  $\sigma$ ,  $\mathbf{x}$  e  $\boldsymbol{\beta}$ . Os efeitos marginais deste modelo na subpopulação podem ser obtidos escrevendo

$$E[y_i | y_i > a] = \mathbf{x}'_i \boldsymbol{\beta} + \sigma \lambda(\alpha_i)$$

onde agora  $\alpha_i = (a - \mathbf{x}'_i \boldsymbol{\beta}) / \sigma$ . Por conveniência, seja  $\lambda_i = \lambda(\alpha_i)$  e  $\delta_i = \delta(\alpha_i)$ . Então

$$\begin{aligned} \frac{\partial E[y_i | y_i > a]}{\partial \mathbf{x}_i} &= \boldsymbol{\beta} + \sigma (d\lambda_i / d\alpha_i) \frac{\partial \alpha_i}{\partial \mathbf{x}_i} \\ &= \boldsymbol{\beta} + \sigma (\lambda_i^2 - \alpha_i \lambda_i) (-\boldsymbol{\beta} / \sigma) = \boldsymbol{\beta} (1 - \lambda_i^2 + \alpha_i \lambda_i) \\ &= \boldsymbol{\beta} (1 - \delta_i) \end{aligned}$$



# Consequências

- Para cada elemento de  $\mathbf{x}_i$ , o efeito marginal é menor que o coeficiente correspondente, e uma atenuação semelhante da variância.
- Se o efeito marginal do slide anterior ou o próprio coeficiente  $\beta$  é de interesse depende das inferências pretendidas do estudo.
- A primeira inclinação pode ser usar mínimos quadrados ordinários para estimar os parâmetros desse modelo de regressão. Para a subpopulação da qual os dados são extraídos, poderíamos escrever o modelo na forma

$$y_i \mid y_i > a = E[y_i \mid y_i > a] + u_i = \mathbf{x}_i' \beta + \sigma \lambda_i + u_i,$$

onde  $u_i$  é  $y_i$  menos sua expectativa condicional. Se estimarmos isso por regressão de mínimos quadrados ordinários de  $\mathbf{y}$  em  $\mathbf{X}$ , então omitimos uma variável, o termo não linear  $\lambda_i$ .



# Censura

Um problema muito comum em dados microeconômicos é a censura da variável dependente. Quando a variável dependente é censurada, os valores em um determinado intervalo são todos transformados em (ou relatados como) um único valor. Alguns exemplos que apareceram na literatura empírica são os seguintes:

- ① Compras domésticas de bens duráveis [Tobin (1958)],
- ② O número de casos extraconjugais [Fair (1977,1978)],
- ③ O número de horas trabalhadas por uma mulher na força de trabalho [Quester e Greene (1982)]
- ④ O número de prisões após a libertação da prisão [Witte (1980)],



# Distribuição Normal Censurada



- A teoria de distribuição relevante para uma variável censurada é semelhante àquela para uma truncada.
- Mais uma vez, começamos com a distribuição normal, pois muito do trabalho recebido foi baseado em uma suposição de normalidade. Também assumimos que o ponto de censura é zero, embora isso seja apenas uma normalização conveniente.
- Em uma distribuição truncada, apenas a parte da distribuição acima de  $y = 0$  é relevante para nossos cálculos.
- Para fazer a distribuição integrar a um, nós a escalamos pela probabilidade de que uma observação na população não truncada caia no intervalo que nos interessa.
- Quando os dados são censurados, a distribuição que se aplica aos dados de amostra é uma mistura de distribuições discretas e contínuas.
- Para analisar esta distribuição, definimos uma nova variável aleatória  $y$  transformada da original,  $y^*$ , por

$$\begin{aligned} y &= 0 && \text{if } y^* \leq 0, \\ y &= y^* && \text{if } y^* > 0. \end{aligned}$$



# Normal Censurada II

- A distribuição que se aplica se  $y^* \sim N[\mu, \sigma^2]$  é  $\text{Prob}(y = 0) = \text{Prob}(y^* \leq 0) = \Phi(-\mu/\sigma) = 1 - \Phi(\mu/\sigma)$ , e se  $y^* > 0$ , então  $y$  tem a densidade de  $y^*$ .
- Esta distribuição é uma mistura de partes discretas e contínuas. A probabilidade total é um, conforme necessário, mas em vez de redimensionar a segunda parte, simplesmente atribuímos a probabilidade total na região censurada ao ponto de censura, neste caso, zero.



# Momentos da Normal Censurada

## Theorem (Momentos da Normal Censurada)

Se  $y^* \sim N[\mu, \sigma^2]$  e  $y = a$  se  $y^* \leq a$  ou então  $y = y^*$ , então

$$E[y] = \Phi a + (1 - \Phi)(\mu + \sigma\lambda)$$

e

$$\text{Var}[y] = \sigma^2(1 - \Phi) [(1 - \delta) + (\alpha - \lambda)^2\Phi]$$

onde

$$\Phi[(a - \mu)/\sigma] = \Phi(\alpha) = \text{Prob}(y^* \leq a) = \Phi, \quad \lambda = \phi/(1 - \Phi)$$

e

$$\delta = \lambda^2 - \lambda\alpha$$

# Modelo TOBIT

A formulação geral é geralmente dada em termos de uma função de índice,

$$\begin{aligned}y_i^* &= \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i, \\y_i &= 0 \quad \text{if } y_i^* \leq 0, \\y_i &= y_i^* \quad \text{if } y_i^* > 0.\end{aligned}$$

para uma observação extraída aleatoriamente da população, que pode ou não ser censurada,

$$E[y_i | \mathbf{x}_i] = \Phi\left(\frac{\mathbf{x}_i' \boldsymbol{\beta}}{\sigma}\right) (\mathbf{x}_i' \boldsymbol{\beta} + \sigma \lambda_i),$$

onde

$$\lambda_i = \frac{\phi[(0 - \mathbf{x}_i' \boldsymbol{\beta}) / \sigma]}{1 - \Phi[(0 - \mathbf{x}_i' \boldsymbol{\beta}) / \sigma]} = \frac{\phi(\mathbf{x}_i' \boldsymbol{\beta} / \sigma)}{\Phi(\mathbf{x}_i' \boldsymbol{\beta} / \sigma)}.$$





## TOBIT II

## Theorem (Efeitos Marginais no Modelo de Regressão Censurada)

*No modelo de regressão censurada com regressão latente  $y^* = \mathbf{x}'\beta + \varepsilon$  e variável dependente observada,  $y = a$  se  $y^* \leq a$ ,  $y = b$  se  $y^* \geq b$ , e  $y = y^*$  caso contrário, onde  $a$  e  $b$  constantes, seja  $f(\varepsilon)$  e  $F(\varepsilon)$  denotam a densidade e cdf de  $\varepsilon$ . Assuma que  $\varepsilon$  é uma variável aleatória contínua com média 0 e variância  $\sigma^2$ , e  $f(\varepsilon | \mathbf{x}) = f(\varepsilon)$ . Então*

$$\frac{\partial E[y | \mathbf{x}]}{\partial \mathbf{x}} = \beta \times \text{Prob}[a < y^* < b]$$

## Efeitos Marginais III

McDonald e Mofitt (1980) sugeriram uma decomposição útil de  $\partial E[y_i | \mathbf{x}_i] / \partial \mathbf{x}_i$ ,

$$\frac{\partial E[y_i | \mathbf{x}_i]}{\partial \mathbf{x}_i} = \beta \times \{ \Phi_i [1 - \lambda_i (\alpha_i + \lambda_i)] + \phi_i (\alpha_i + \lambda_i) \}$$

onde  $\alpha_i = \mathbf{x}_i' \beta$ ,  $\Phi_i = \Phi(\alpha_i)$  e  $\lambda_i = \phi_i / \Phi_i$ . Tomando as duas partes separadamente, este resultado decompõe o vetor inclinação em

$$\frac{\partial E[y_i | \mathbf{x}_i]}{\partial \mathbf{x}_i} = \text{Prob}[y_i > 0] \frac{\partial E[y_i | \mathbf{x}_i, y_i > 0]}{\partial \mathbf{x}_i} + E[y_i | \mathbf{x}_i, y_i > 0] \frac{\partial \text{Prob}[y_i > 0]}{\partial \mathbf{x}_i}.$$

Assim, uma mudança em  $\mathbf{x}_i$  tem dois efeitos: afeta a média condicional de  $y_i^*$  na parte positiva da distribuição e afeta a probabilidade de que a observação cairá nessa parte da distribuição.



# TOBIT - Estimação

A estimação é por Máxima Verossimilhança A função log-verossimilhança é dada por:

$$\ln L = \sum_{y_i > 0} -\frac{1}{2} \left[ \log(2\pi) + \ln \sigma^2 + \frac{(y_i - \mathbf{x}'_i \boldsymbol{\beta})^2}{\sigma^2} \right] + \sum_{y_i = 0} \ln \left[ 1 - \Phi \left( \frac{\mathbf{x}'_i \boldsymbol{\beta}}{\sigma} \right) \right]$$

As duas partes correspondem à regressão clássica para as observações não-limite e as probabilidades relevantes para as observações limite, respectivamente. Com  $\gamma = \boldsymbol{\beta}/\sigma$  and  $\theta = 1/\sigma$ , a log-verossimilhança é

$$\ln L = \sum_{y_i > 0} -\frac{1}{2} \left[ \ln(2\pi) - \ln \theta^2 + (\theta y_i - \mathbf{x}'_i \boldsymbol{\gamma})^2 \right] + \sum_{y_i = 0} \ln [1 - \Phi (\mathbf{x}'_i \boldsymbol{\gamma})] .$$



## Seleção de Amostra - Truncagem Incidental

- Suponha que  $y$  e  $z$  tenham uma distribuição bivariada com correlação  $\rho$ .
- Estamos interessados na distribuição de  $y$  dado que  $z$  excede um determinado valor.
- A intuição sugere que se  $y$  e  $z$  estiverem positivamente correlacionados, então o truncamento de  $z$  deve empurrar a distribuição de  $y$  para a direita.
- Como antes, estamos interessados em (1) a forma da distribuição acidentalmente truncada e (2) a média e a variância da variável aleatória acidentalmente truncada.
- Vamos nos concentrar primeiro na distribuição normal bivariada.

A densidade conjunta truncada de  $y$  e  $z$  é

$$f(y, z \mid z > a) = \frac{f(y, z)}{\text{Prob}(z > a)}.$$

Para obter a densidade marginal truncada incidentalmente para  $y$ , integraríamos  $z$  para fora dessa expressão.



# Momentos - Truncagem Incidental

## Theorem (Momentos da Distribuição Normal Bivariada Incidentalmente Truncada)

*Se  $y$  e  $z$  têm uma distribuição normal bivariada com médias  $\mu_y$  e  $\mu_z$ , desvios padrão  $\sigma_y$  e  $\sigma_z$ , e correlação  $\rho$ , então*

$$E[y \mid z > a] = \mu_y + \rho\sigma_y\lambda(\alpha_z),$$
$$\text{Var}[y \mid z > a] = \sigma_y^2 [1 - \rho^2\delta(\alpha_z)],$$

*onde*

$$\alpha_z = (a - \mu_z) / \sigma_z, \lambda(\alpha_z) = \phi(\alpha_z) / [1 - \Phi(\alpha_z)], \text{ e } \delta(\alpha_z) = \lambda(\alpha_z) [\lambda(\alpha_z) - \alpha_z]$$



# Modelo de Seleção

Para colocar os exemplos anteriores em uma estrutura geral, deixe a equação que determina a seleção da amostra ser

$$z_i^* = \mathbf{w}'\boldsymbol{\gamma}_i + u_i$$

e deixe a equação de interesse ser

$$y_i = \mathbf{x}_i'\boldsymbol{\beta} + \varepsilon_i$$

A regra é que  $y_i$  é observado apenas quando  $z_i^*$  é maior que zero. Suponha também que  $\varepsilon_i$  e  $u_i$  tenham uma distribuição normal bivariada com média zero e correlação  $\rho$ . Então podemos inseri-los no Teorema 22.5 para obter o modelo que se aplica às observações em nossa amostra:

$$\begin{aligned} E[y_i \mid y_i \text{ is observed}] &= E[y_i \mid z_i^* > 0] \\ &= E[y_i \mid u_i > -\mathbf{w}'\boldsymbol{\gamma}_i] \\ &= \mathbf{x}_i'\boldsymbol{\beta} + E[\varepsilon_i \mid u_i > -\mathbf{w}'\boldsymbol{\gamma}_i] \\ &= \mathbf{x}_i'\boldsymbol{\beta} + \rho\sigma_\varepsilon\lambda_i(\alpha_u) \\ &= \mathbf{x}_i'\boldsymbol{\beta}_i + \beta_\lambda\lambda_i(\alpha_u), \end{aligned}$$



## Modelo de Seleção II

where  $\alpha_u = -\mathbf{w}'_i \gamma / \sigma_u$  and  $\lambda(\alpha_u) = \phi(\mathbf{w}'_i \gamma / \sigma_u) / \Phi(\mathbf{w}'_i \gamma / \sigma_u)$ . So

$$\begin{aligned} y_i \mid z_i^* > 0 &= E[y_i \mid z_i^* > 0] + v_i \\ &= \mathbf{x}'_i \boldsymbol{\beta} + \beta_\lambda \lambda_i(\alpha_u) + v_i. \end{aligned}$$

- A regressão de OLS usando os dados para os quais temos informação produz estimativas inconsistentes de  $\boldsymbol{\beta}$ .
- Mais uma vez, podemos ver o problema como uma variável omitida.
- A regressão de mínimos quadrados de  $y$  em  $\mathbf{x}$  e  $\lambda$  seria um estimador consistente, mas se  $\lambda$  for omitido, o erro de especificação de uma variável omitida será cometido.
- Finalmente, observe que a segunda parte do Teorema 22.5 implica que mesmo se  $\lambda_i$  fosse observado, os mínimos quadrados seriam ineficientes. A perturbação  $v_i$  é heterocedástica.



## Modelo de Seleção III

Mecanismo de Seleção:  $z_i^* = \mathbf{w}_i' \boldsymbol{\gamma} + u_i$ ,  $z_i = 1$  if  $z_i^* > 0$  e 0 caso contrário;

$\text{Prob}(z_i = 1 \mid \mathbf{w}_i) = \Phi(\mathbf{w}_i' \boldsymbol{\gamma})$  e

$\text{Prob}(z_i = 0 \mid \mathbf{w}_i) = 1 - \Phi(\mathbf{w}_i' \boldsymbol{\gamma})$ .

Modelo de Regressão:  $y_i = \mathbf{x}_i' \boldsymbol{\beta} + \varepsilon_i$  observado somente se  $z_i = 1$ ,

$$(u_i, \varepsilon_i) \sim \text{normal bivariada } [0, 0, 1, \sigma_\varepsilon, \rho].$$

Suponha que, como em muitos desses estudos,  $z_i$  e  $\mathbf{w}_i$  sejam observados para uma amostra aleatória de indivíduos, mas  $y_i$  seja observado apenas quando  $z_i = 1$ . Este modelo é precisamente o que examinamos anteriormente, com

$$E[y_i \mid z_i = 1, \mathbf{x}_i, \mathbf{w}_i] = \mathbf{x}_i' \boldsymbol{\beta} + \rho \sigma_\varepsilon \lambda(\mathbf{w}_i' \boldsymbol{\gamma})$$





# Efeitos Marginais

- O efeito marginal dos regressores em  $y_i$  na amostra observada consiste em dois componentes.
- Existe o efeito direto na média de  $y_i$ , que é  $\beta$ .
- Além disso, para uma determinada variável independente, se ela aparecer na probabilidade de que  $z_i^*$  seja positiva, ela influenciará  $y_i$  por meio de sua presença em  $\lambda_i$ .
- O efeito total das mudanças em um regressor que aparece em  $\mathbf{x}_i$  e  $\mathbf{w}_i$  em  $y$  é

$$\frac{\partial E[y_i \mid z_i^* > 0]}{\partial x_{ik}} = \beta_k - \gamma_k \left( \frac{\rho \sigma_\varepsilon}{\sigma_u} \right) \delta_i(\alpha_u),$$

onde

$$\delta_i = \lambda_i^2 - \alpha_i \lambda_i$$



# Modelo de Seleção - Estimação em dois estágios

Os parâmetros do modelo de seleção amostral podem ser estimados por máxima verossimilhança. No entanto, o procedimento de estimativa em duas etapas de Heckman (1979) geralmente é usado. O método de Heckman é o seguinte.

- 1 Estime a equação probit por máxima verossimilhança para obter estimativas de  $\gamma$ .

Para cada observação na amostra selecionada, calcule  $\hat{\lambda}_i = \phi(\mathbf{w}'_i \hat{\gamma}) / \Phi(\mathbf{w}'_i \hat{\gamma})$  e

$$\hat{\delta}_i = \hat{\lambda}_i (\hat{\lambda}_i - \mathbf{w}'_i \hat{\gamma})$$

- 2 Estimar  $\beta$  e  $\beta_\lambda = \rho \sigma_e$  por regressão de mínimos quadrados de  $y$  em  $\mathbf{x}$  e  $\hat{\lambda}$ .

É possível também construir estimadores consistentes dos parâmetros individuais  $\rho$  e  $\sigma_e$ .

